

04/05

ANSÄTZE, METHODEN UND ANWENDUNGEN KÜNSTLICHER INTELLIGENZ (KI)

KURSinHALTE UND TERMINE

Kursinhalte

Data Science	1
Statistische Grundlagen	2
Softwareentwicklung	3
Methoden und Anwendungen Künstlicher Intelligenz (KI)	4-5
Testing / Integration / Deployment	6
Methoden und Anwendungen Künstlicher Intelligenz (KI)	7-8
Zusammenfassung / Fragen / Klausurvorbereitung	9

Termine

#	Wochentag	Datum	von - bis	Räume
1	Freitag	04.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
2	Freitag	11.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.27 Bothfeld
3	Freitag	25.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
4	Freitag	16.05.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
5	Freitag	23.05.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
6	Freitag	06.06.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
7	Freitag	20.06.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
8	Freitag	04.07.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
9	Freitag	11.07.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt

Methoden und Anwendungen Künstlicher Intelligenz (KI)

Lernziele

Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- Wie sich **Analysemethoden** nach **Art de Komplexität** unterscheiden lassen
- was das **Grundprinzip der Clusteranalyse** ist und wie sich dieses **Anwenden** lässt
- was das **Grundprinzip der Assoziationsanalyse** ist und wie sich dieses **Anwenden** lässt




ZEICHEN, DATEN, INFORMATIONEN, WISSEN

- Aus vernetzten Informationen kann Wissen entstehen (Wissen als Basis für Handlungen, unter Berücksichtigung von Erfahrung)
- Erst durch die Übertragung in einen Kontext bekommen Daten eine Bedeutung und werden zu Informationen
- Durch die Zusammensetzung von Zeichen in einen strukturierten Zusammenhang (einer Syntax folgend) entstehen Daten
- Vorrat verschiedener Zeichen auf unterster Ebene




Quelle Grafik: nach Krcmar, H. (2011).

WISSENSPYRAMIDE / DIKW PYRAMIDE




Quelle Grafik: [Wissen – Wikipedia](#)



Quelle Grafik: [DIKW pyramid – Wikipedia](#) (nach Ackoff)

WISSEN, KÖNNEN, KOMPETENZEN



Quelle Grafik: Wissen, Können, Kompetenzen (nach Völker, 2007)

LATENZZEITEN

- **Datenlatenz**

Zeit vom Ereignis bis zur Erfassung der Daten

- **Analyselatenz**


Zeit von der Datenerfassung bis zur Verfügbarkeit der Analyse

- **Entscheidungslatenz**

Zeit von der Verfügbarkeit der Analyse bis zur Entscheidung

- **Umsetzungslatenz**

Zeit von der Entscheidung bis zur Umsetzung



Quelle Grafik: Dorschel et al., 2015, Seite 60 nach Kemper, Baars, and Mehanna, 2010).

ANALYSEMETHODEN

Analysemethoden, klassifiziert nach
menschlichem Einfluss und zeitlicher
Ausrichtung der Analyse:

Vergangenheitsorientiert


— **Descriptive Analytics**

— **Diagnostic Analytics**

Zukunftsorientiert

— **Predictive Analytics**

— **Prescriptive Analytics**




Quelle Grafik: [Gartner Says Advanced Analytics Is a Top Business Priority](#), 2014

Quelle: [Gartner Says Advanced Analytics Is a Top Business Priority](#)

ANALYSEMETHODEN


Analysemethoden, klassifiziert nach Komplexität und Wert für ein Unternehmen:

- **Descriptive Analytics**
- **Diagnostic Analytics**
- **Real-time Analytics**
- **Predictive Analytics**
- **Prescriptive Analytics**



Quelle Grafik: Dorschel et al., 2015, Seite 56.

ANALYTICS-VERFAHREN VERWENDUNGSZWECK



Quelle Grafik: Gluchowski, Schieder, Chamoni 2021 nach Dorschel 2015.

Zuordnung von
Objekten in
undefinierte Gruppen
(ohne Label Attribut)
„Unüberwachtes
Lernen“

Auffinden von statistischen
Zusammenhängen (Assoziation)
zwischen verschiedenen
Objekten in einem Datensatz.
Ableitung von signifikanten
Assoziationsregeln.

Zuordnung von Objekten in zuvor definierte Klassen
(basierend auf Beispieldatensätzen mit Label Attribut)
„Überwachtes Lernen“ (mit Training- und Test-Datensatz)

Methoden und Anwendungen Künstlicher Intelligenz (KI)

Übungsfragen



1. Nenne **jeweils ein Beispiel** für **Zeichen, Daten, Informationen, Wissen!**
2. Welche **Latenzzeiten** lassen sich bei Datenanalyse-Projekten unterscheiden?
3. Welche **Analysemethoden** lassen sich mit Blick auf **menschlichem Einfluss** und **zeitlicher Ausrichtung** unterscheiden?
 - Welche davon sind **Vergangenheitsorientiert**?
 - Welche davon sind **Zukunftsorientiert**?
 - Welche davon **ermöglicht „Decision Automation“**?
4. Nenne **2 Verfahren** für die **Vorhersage (Prediction)**!
5. Nenne **2 Verfahren** für die **Beschreibung (Description)**!

Methoden und Anwendungen Künstlicher Intelligenz (KI)


Lernziele

Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- Wie sich **Analysemethoden** nach **Art de Komplexität** unterscheiden lassen
- was das **Grundprinzip der Clusteranalyse** ist und wie sich dieses **Anwenden** lässt
- was das **Grundprinzip der Assoziationsanalyse** ist und wie sich dieses **Anwenden** lässt



ANALYTICS-VERFAHREN VERWENDUNGSZWECK




Quelle Grafik: Gluchowski, Schieder, Chamoni 2021 nach Dorschel 2015.

Zuordnung von Objekten in undefinierte Gruppen (ohne Label Attribut) „Unüberwachtes Lernen“

Auffinden von statistischen Zusammenhängen (Assoziation) zwischen verschiedenen Objekten in einem Datensatz. Ableitung von signifikanten Assoziationsregeln.

Zuordnung von Objekten in zuvor definierte Klassen (basierend auf Beispieldatensätzen mit Label Attribut) „Überwachtes Lernen“ (mit Training- und Test-Datensatz)

SEGMENTIERUNG (CLUSTERING)




CLUSTERING

„Clustering ist ein unüberwachtes Lernverfahren, bei dem unmarkierte Daten Clustern zugeordnet werden. (Runkler 2015, S.109)

Häufig verwendete Methoden für das Clustering:

- **Sequenzielles Clustering**
Relativ einfach zu Implementieren, jedoch hoher Rechenaufwand (bspw. Single-Linkage, Complete-Linkage, Average-Linkage, Ward-Methode)
- **Prototypbasiertes Clustering**
Unterscheidung nach
 - den **Clustermodellen** (scharf, fuzzy, possibilistisch, Ausreißer)
 - den **Prototypen** (Hypersphären, Ellipsoide, Linien, Hyperebenen, Kreise, komplexe Formen)
 - weiteren **Spezifika** (medoid-basierte, relationale, Kernel, heuristische Verfahren)




Quelle: Runkler, 2015, S. 110

DATENSATZ UND CLUSTER IM STREUDIAGRAMM

Datensatz:

$X = \{(2,2), (3,2), (4,3), (6,7), (7,8), (8,8), (5,5)\}$

Streudiagramm zeigt die Verteilung und Clusterstruktur.



Quelle: Runkler, 2015, S. 111.


SEQUENZIELLES CLUSTERING

Beim **sequenzielle agglomerativen hierarchischen Clustering** wird zu Beginn jeder der Datenpunkte als ein Cluster interpretiert.


- Im ersten Schritt wird das Paar mit dem geringsten Abstand berechnet und zu einem Cluster zusammengefasst. Dadurch hat sich die Zahl der Cluster um 1 verringert.
- Dieses Vorgehen wird fortgesetzt bis die Zahl der determinierten Cluster erreicht ist.

Der Abstand zwischen einem Paar von Clustern kann aus den paarweisen Abständen der zugehörigen Punkte berechnet werden:


- **Minimalabstand (engl. Single Linkage)**
- **Maximalabstand (engl. Complete Linkage)**
- **Mittlere Abstand (engl. Average Linkage)**



Minimal- und Maximalabstand



Mittlerer Abstand



Dendrogramm

Quelle: Runkler, 2015, S. 113.


Mit einem **Dendrogramm** kann die hierarchische Struktur der Partitionen dargestellt werden. Man sieht hier wie die Punkte sukzessive zusammengefasst werden.

CLUSTERING

K-MEANS-CLUSTERING

K-Means-Clustering

- misst Ähnlichkeit anhand der gewöhnlichen geradlinigen Entfernung (also der euklidischen Distanz).
- erstellt Cluster, indem es eine bestimmte Anzahl von Punkten – sogenannte **Zentroiden** – im Merkmalsraum platziert. Jeder Punkt im Datensatz wird dem Cluster desjenigen Zentroids zugewiesen, dem er am nächsten liegt.
- Das „**k**“ in „**k-means**“ gibt an, wie viele Zentroiden (also Cluster) erstellt werden. Diesen Wert legst du selbst fest.
- Man kann sich vorstellen, dass jeder Zentroid Punkte durch eine Reihe von ausstrahlenden Kreisen „einfängt“. Wenn sich die Kreise von benachbarten Zentroiden überschneiden, entsteht eine Linie.
- Das Ergebnis ist eine sogenannte **Voronoi-Tessellation**. Diese zeigt, welchen Clustern zukünftige Datenpunkte zugewiesen werden – im Grunde ist diese Tessellation das, was k-means aus den Trainingsdaten „lernt“



<https://www.kaggle.com/code/ryanholbrook/clustering-with-k-means>

CLUSTERING

K-MEANS-CLUSTERING



- **K-Means-Algorithmus** (Lernen der Cluster und Feature Engineering)
- Blick auf drei Parameter aus der scikit-learn-Implementierung:
 - **n_clusters**, **max_iter** und **n_init**
- Algorithmus folgt einem Zwei-Schritte-Verfahren:
- Zunächst werden zufällig eine bestimmte Anzahl von Zentroiden initialisiert – festgelegt durch den Parameter n_clusters. Anschließend wiederholt der Algorithmus diese beiden Schritte:
 1. Zuweisung: Jeder Punkt wird dem nächstgelegenen Zentroid zugewiesen.
 2. Verschiebung: Jedes Zentroid wird neu berechnet, sodass es näher an den ihm zugewiesenen Punkten liegt (zur Minimierung der Distanz).
- Diese Schritte werden solange wiederholt, bis sich die Zentroiden nicht mehr bewegen oder eine maximale Anzahl von Iterationen erreicht ist (max_iter).
- Häufig kommt es vor, dass eine ungünstige zufällige Anfangsposition der Zentroiden zu einer schlechten Clusterbildung führt. Daher wiederholt der Algorithmus den Vorgang mehrmals (n_init) und wählt am Ende das beste Clustering-Ergebnis – also jenes mit der geringsten Gesamtdistanz zwischen den Punkten und ihren jeweiligen Zentroiden.



<https://www.kaggle.com/code/ryanholbrook/clustering-with-k-means>

CLUSTERING


- Auf nur ein Feature bezogen bekommt man ein Ergebnis wie beim Binning oder Discretization
- Auf mehrere Features bezogen bekommt man eine Art multidimensionales binning.
- Das Ergebnis sind mehrere Cluster deren Label wiederum kategorial (bspw. Cluster A, B ,C, D) ist.



<https://www.kaggle.com/code/ryanholbrook/clustering-with-k-means>

CLUSTERING

- Die Bildung von Clustern kann dabei unterstützen bessere lineare Modelle zu erzeugen.
- Durch die Bildung von Clustern können passendere Modelle pro Cluster berechnet werden, anstatt ein Modell für alle Daten




<https://www.kaggle.com/code/ryanholbrook/clustering-with-k-means>

ELBOW METHODE

- Wenn man zu viele oder zu wenige Cluster wählt, ist das Ergebnis des Clustering-Verfahrens oft nicht optimal. Die Elbow-Methode hilft, eine sinnvolle Anzahl an Clustern zu finden, indem man misst, wie stark sich der **Fehler (z. B. die Varianz innerhalb der Cluster)** mit zunehmender Anzahl an Clustern verringert.

Vorgehen:

1. Führe K-Means-Clustering für verschiedene Werte von **k** (Anzahl der Cluster) durch, z. B. $k = 1$ bis 10.
2. Berechne für jedes **k** den "**inertia**"-Wert (Summe der quadrierten Abstände aller Punkte zum nächsten Cluster-Zentrum).
3. Zeichne **k** gegen den Fehlerwert (inertia).
4. Der "Knick" oder "Ellbogen" in der Kurve zeigt die optimale Clusteranzahl an.



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen


Szenario:

Ein Gebrauchtwagenhändler (GWH) hat viele Daten über gebrauchte Fahrzeuge gesammelt. Er möchte herausfinden, ob es **Cluster** in den Daten gibt. Ein **Cluster** hat möglichst **homogene Attributausprägungen innerhalb eines Clusters** und möglichst **heterogenen Attributausprägungen zwischen den Clustern**.

Ziel: Analyse der Daten zu Gebrauchtwagen hinsichtlich Cluster in den Attributen

Vorgehen nach dem CRISP-DM Prozess in 6 Schritten:

1. Business Understanding (Aufgabendefinition)
2. Data Understanding (Datenverständnis / EDA)
3. Data Preparation (Datenaufbereitung)
4. Modeling (Auswahl und Anwendung von Modellen)
5. Evaluation (Bewertung und Interpretation der Ergebnisse)
6. Deployment (Anwendung der Ergebnisse)




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

CRISP-DM PHASEN UND AKTIVITÄTEN

Aufgabendefinition	Datenverständnis	Datenaufbereitung
Business Understanding	Data Understanding	Data Preparation
- Bestimmung der betriebswirtschaftlichen Problemstellung - Situationsbewertung - Bestimmung analytischer Ziele - Erstellung eines Projektplans	- Daten sammeln - Daten beschreiben - Untersuchung der Daten - Verifizierung der Datenqualität	- Auswahl der Daten - Bereinigung der Daten - Transformation und Integration der Daten - Daten-formatierung

Die Datenaufbereitung nimmt zwischen 40-70 % der Zeit in Anspruch


Quelle: Datenaufbereitung im Mining-Prozess - IBM Dokumentation



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

CRISP-DM PHASEN UND AKTIVITÄTEN

Modellierung	Bewertung	Anwendung
Modeling	Evaluation	Deployment
• Auswahl des Modells • Testmodell erstellen • Modell erstellen	• Bewertung des Modells • Bewertung der Resultate • Bewertung des Prozesses • Nächste Schritte festlegen	• Zusammenfassender Bericht und Präsentation der Ergebnisse • Implementierungsstrategie planen • Überwachung der Gültigkeit der Modelle planen




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten

Schritt 1: Business Understanding

- **Bestimmung der betriebswirtschaftlichen Problemstellung**
 - Ein Gebrauchtwagenhändler (GWH) möchte den Preis für verfügbare Gebrauchtwagen mittels eines Modells bestimmen. Bisher wird der Preis auf Basis der Erfahrungswerte der Mitarbeiter bestimmt. Der Preis soll für die Kunden und im Vergleich zum Markt akzeptabel sein und gleichzeitig eine hohe Marge für den Händler einbringen. Durch den Einsatz einer datenbasierten Entscheidungsunterstützung soll gezeigt werden, ob es Potenzial für höhere Margen gibt.
- **Situationsbewertung**
 - Der GWH hat Daten über verkaufte Gebrauchtwagen über die Plattform kaggle bezogen. Die Grundlage für eine Datenanalyse ist damit vorhanden. Der aktuelle Prozess ist stark von der Erfahrung der jeweiligen Mitarbeiter abhängig. Ein datenbasierter und systemgestützter Prozess könnte diese starke Abhängigkeit entlasten und die Mitarbeiter bei Ihren Entscheidungen unterstützen. Es besteht die Chance neue Erkenntnisse aus Daten zu erlangen und bisher ungenutzte Potenziale zu heben.
- **Bestimmung analytischer Ziele**
 - Identifizierung von Clustern in den Daten und deren Einfluss auf das Ziel-Attribut „Preis“
- **Erstellung eines Projektplans**
 - Zusammenstellen eines Teams (Rollen, Verantwortungen festlegen)
 - Vorgehen nach den CRISP-DM (Phasen und Dauer planen)
 - Ergebnisse dem Auftraggeber präsentieren




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Daten sammeln
 - Die Daten wurden von kaggle bezogen:
<https://www.kaggle.com/datasets/adityadesai13/used-car-dataset-ford-and-mercedes/data>



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Daten beschreiben

(10668, 9)

```
Index(['model', 'year', 'price', 'transmission', 'mileage', 'fuelType', 'tax',
      'mpg', 'engineSize'],
      dtype='object')
```

	year	price	mileage	tax	mpg	engineSize
count	10668.000000	10668.000000	10668.000000	10668.000000	10668.000000	10668.000000
mean	2017.100675	22896.685039	24827.244001	126.011436	50.770022	1.930709
std	2.167494	11714.841888	23505.257205	67.170294	12.949782	0.602957
min	1997.000000	1490.000000	1.000000	0.000000	18.900000	0.000000
25%	2016.000000	15130.750000	5968.750000	125.000000	40.900000	1.500000
50%	2017.000000	20200.000000	19000.000000	145.000000	49.600000	2.000000
75%	2019.000000	27990.000000	36464.500000	145.000000	58.900000	2.000000
max	2020.000000	145000.000000	323000.000000	580.000000	188.300000	6.300000

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	A1	2017	12500	Manual	15735	Petrol	150	55.4	1.4
1	A6	2016	16500	Automatic	36203	Diesel	20	64.2	2.0
2	A1	2016	11000	Manual	29946	Petrol	30	55.4	1.4
3	A4	2017	16800	Automatic	25952	Diesel	145	67.3	2.0
4	A3	2019	17300	Manual	1998	Petrol	145	49.6	1.0

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10668 entries, 0 to 10667
Data columns (total 9 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   model           10668 non-null  object
1   year            10668 non-null  int64
2   price           10668 non-null  int64
3   transmission    10668 non-null  object
4   mileage         10668 non-null  int64
5   fuelType        10668 non-null  object
6   tax             10668 non-null  int64
7   mpg             10668 non-null  float64
8   engineSize      10668 non-null  float64
dtypes: float64(2), int64(4), object(3)
memory usage: 750.2+ KB
```

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Untersuchung der Daten (EDA)



	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	A1	2017	12500	Manual	15735	Petrol	150	55.4	1.4
1	A6	2016	16500	Automatic	36203	Diesel	20	64.2	2.0
2	A1	2016	11000	Manual	29946	Petrol	30	55.4	1.4
3	A4	2017	16800	Automatic	25952	Diesel	145	67.3	2.0
4	A3	2019	17300	Manual	1998	Petrol	145	49.6	1.0


```
model Ordinal (Reihenfolge vorhanden)
year Intervallskala
price Intervallskala
transmission Nominal (kategorisch)
mileage Intervallskala
fuelType Nominal (kategorisch)
tax Verhältnisskala
mpg Intervallskala
engineSize Verhältnisskala
```

Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten

Schritt 2: Data Understanding

- Untersuchung der Daten (EDA)




Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Untersuchung der Daten (EDA)




Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Untersuchung der Daten (EDA)




Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Untersuchung der Daten (EDA)




Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten

Schritt 2: Data Understanding



- Untersuchung der Daten (EDA)




Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten

Schritt 2: Data Understanding

- Untersuchung der Daten (EDA)




Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

Name: count, dtype: int64



model	
A3	1929
Q3	1417
A4	1381
A1	1347
A5	882
Q5	877
Q2	822
A6	748
Q7	397
TT	336
A7	122
A8	118
Q8	69
RS6	39
RS3	33
RS4	31
RS5	29
R8	28
S3	18
SQ5	16
S4	12
SQ7	8
S8	4
S5	3
A2	1
RS7	1




Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Untersuchung der Daten (EDA)




Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten

Schritt 2: Data Understanding


- Untersuchung der Daten (EDA)



Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten

Schritt 2: Data Understanding



Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten


Schritt 2: Data Understanding



Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten


Schritt 2: Data Understanding



Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten

Schritt 2: Data Understanding




Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten

Schritt 2: Data Understanding

- Untersuchung der Daten (EDA)




Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Verifizierung der Datenqualität
 - Fehlende Werte
 - Mit Wert belegen oder NA lassen oder Entfernen
 - Hier: Gute Datenqualität => keine fehlenden Werte
 - Duplikate
 - Analyse ob sinnvolle Duplikate oder Entfernen
 - Überschreiben oder bereinigten Datensatz verwenden
 - Skalenniveau
 - Skalenniveau bei Bedarf anpassen
 - bspw. Nominal to Numerical mittels „Label Encoding“ oder „One-Hot-Encoding“
 - Verteilung und Ausreißer
 - Identifizieren
 - Gegebenenfalls Entfernen oder Normalisierung der Daten



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Explorative Datenanalyse für das Clustering

20 Minuten Zeit



Aufgabe:

1. Findet euch in euren **Teams aus 2 Personen** zusammen.
2. Arbeitet als Team im Sinne des “Extreme Programming” (XP) nach der Kernpraktik “Pair Programming”
3. Erstellt auf Basis einer der Datensätze zu Gebrauchtfahrzeugen “**used_car.csv**“ ein Notebook mit Informationen zu den folgenden CRISP-DM Phasen:

- **Business Understanding**
- **Data Understanding (EDA)**

- Hinweis: Das Notebook wird die Basis für eine spätere Cluster-Analyse!



Data Science Software Engineering

Teams

o3

1. Rudi
2. Krzysztof

Hagenberg

1. Patryk
2. Tobias

Housing Hackers

1. Manuel
2. Tijana



kodo no timu

1. Sascha
2. Jeremy

CodeJettters

1. Vincent
2. Cynthia



bwm

ford

hyundai

mercedes


toyota

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Auswahl der Daten
 - Für die Clustering Methode sind keine Nominalen Daten erlaubt
- Bereinigung der Daten
 - Fehlende Werte entfernen oder Ersetzen
 - Duplikate entfernen
 - Evtl. Ausreißer ausschließen
- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig von dem Skalenniveau
 - Nominale Skalen transformieren oder ausschließen
- Datenformatierung
 - Hohe Werte gehen stärker ein, eventuell Werte Normieren



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.


Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Auswahl der Daten
 - Für die Clustering Methode sind keine Nominalen Daten erlaubt
 - model, transmission, fuelType sind nicht metrisch und müssen transformiert oder ausgeschlossen werden!

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	A1	2017	12500	Manual	15735	Petrol	150	55.4	1.4
1	A6	2016	16500	Automatic	36203	Diesel	20	64.2	2.0
2	A1	2016	11000	Manual	29946	Petrol	30	55.4	1.4
3	A4	2017	16800	Automatic	25952	Diesel	145	67.3	2.0
4	A3	2019	17300	Manual	1998	Petrol	145	49.6	1.0



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation


- Bereinigung der Daten

- Fehlende Werte entfernen oder Ersetzen
- Duplikate entfernen
- Ausreißer ausschließen

```
model      0
year       0
price      0
transmission 0
mileage    0
fuelType   0
tax        0
mpg        0
engineSize 0
dtype: int64
```

```
Alle Duplikate (inkl. erstes Vorkommen):
  model year price transmission mileage fuelType tax mpg engineSize
231   Q3  2019  34485   Automatic     10   Diesel  145  47.1      2.0
273   Q3  2019  34485   Automatic     10   Diesel  145  47.1      2.0
277   Q5  2019  31998   Semi-Auto    100   Petrol  145  33.2      2.0
567   Q3  2015  13995    Manual     35446   Diesel  145  54.3      2.0
727   Q2  2019  22495    Manual     1000   Diesel  145  49.6      1.6
...   ...   ...   ...      ...      ...   ...   ...   ...
9524  Q5  2019  44990   Automatic     10   Diesel  145  36.2      2.0
9529  Q5  2019  44990   Automatic     10   Diesel  145  36.2      2.0
9549  Q3  2019  29995    Manual     10   Petrol  145  39.8      1.5
9550  Q3  2019  29995    Manual     10   Petrol  145  39.8      1.5
9597  Q3  2019  28490    Manual     10   Diesel  145  42.8      2.0

[185 rows x 9 columns]
```



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

IQR Methode und Z-Score Methode

Ausreißer ausschließen

IQR steht für *Interquartile Range*, also den Bereich zwischen dem 1. Quartil (Q1) und dem 3. Quartil (Q3). Diese Methode ist **robust gegenüber Ausreißern**, weil sie auf der Mitte der Daten basiert.

Schritte:

1. **Berechne Q1** (25%-Perzentil) und **Q3** (75%-Perzentil) der Daten.
2. **Berechne IQR:**
3. $IQR = Q3 - Q1$
4. **Definiere Ausreißer-Grenzen:**
 1. Untere Grenze: $Q1 - 1,5 \times IQR$
 2. Obere Grenze: $Q3 + 1,5 \times IQR$
5. **Ausreißer:** Alle Werte **außerhalb** dieser Grenzen gelten als Ausreißer.

Beispiel:

- Wenn $Q1 = 10$ und $Q3 = 20$, dann ist
 $IQR = 20 - 10 = 10$
 → untere Grenze = $10 - 1,5 \times 10 = -5$
 → obere Grenze = $20 + 1,5 \times 10 = 35$
 → Werte < -5 oder > 35 sind Ausreißer.

Die Z-Score-Methode basiert auf der **Standardabweichung** und setzt voraus, dass die Daten **annähernd normalverteilt** sind.

Schritte:

1. **Berechne den Mittelwert (μ)** und die **Standardabweichung (σ)** der Daten.
2. **Berechne für jeden Wert den Z-Score:**

$$z = \frac{x - \mu}{\sigma}$$

3. **Ausreißer:** Werte mit einem Z-Score **größer als ± 3** gelten meist als Ausreißer (manchmal $\pm 2,5$ oder ± 2 , je nach Anwendungsfall).

Beispiel:

- Wenn ein Wert einen Z-Score von 3,5 hat, bedeutet das, er liegt 3,5 Standardabweichungen über dem Mittelwert → vermutlich ein Ausreißer.

Kriterium	IQR-Methode	Z-Score-Methode
Verwendet	Quartile	Mittelwert & Standardabweichung
Robust gegenüber Ausreißern	Ja	Nein
Annahme über Verteilung	Keine	Normalverteilung vorausgesetzt
Anwendung bei	Schiefe/verzerrte Daten	Normalverteilte Daten

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten



Schritt 3: Data Preparation

- **Bereinigung der Daten**

- Fehlende Werte entfernen oder Ersetzen
- Duplikate entfernen
- Ausreißer ausschließen
- Hier: Mehrere Ausreißer nach IQR-Methode entfernt bzw. in dataframe „df_clean“

```
   model year  price transmission  mileage fuelType  tax  mpg \
0      A1  2017  12500      Manual   15735   Petrol   150  55.4
3      A4  2017  16800    Automatic   25952   Diesel   145  67.3
4      A3  2019  17300      Manual    1998   Petrol   145  49.6
10     A3  2017  16100      Manual   28955   Petrol   145  58.9
11     A6  2016  16500    Automatic   52198   Diesel   125  57.6
...     ...   ...     ...         ...     ...     ...   ...
10663   A3  2020  16999      Manual    4018   Petrol   145  49.6
10664   A3  2020  16999      Manual    1978   Petrol   150  49.6
10665   A3  2020  17199      Manual     609   Petrol   150  49.6
10666   Q3  2017  19499    Automatic    8646   Petrol   150  47.9
10667   Q3  2016  15999      Manual   11855   Petrol   150  47.9

   engineSize  model_num
0          1.4          0
3          2.0          3
4          1.0          2
10         1.4          2
11         2.0          5
...         ...         ...
10663       1.0          2
10664       1.0          2
10665       1.0          2
10666       1.4          9
10667       1.4          9

[6003 rows x 10 columns]
```

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig vom Skalenniveau der Attribute
 - Nominale Skalen transformieren oder ausschließen

Methode	Wann verwenden?
Label Encoding	Wenn Kategorien ordinal sind (Rangfolge)
One-Hot Encoding	Wenn Kategorien nominal sind (keine Ordnung)



Label Encoding

Farbe	Farbe_num
Rot	0
Blau	1
grün	2

One-Hot Encoding

Farbe_blaue	Farbe_grüne	Farbe_rot
0	0	1
1	0	0
0	1	0
0	0	1
1	0	0

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig vom Skalenniveau der Attribute
 - Nominale Skalen transformieren oder ausschließen
- Hier Attribute model, transmission, fuel_type per One-Hot Encoding in mehrere Spalten transformiert (dataframe df_encoded)

```
0      year price mileage tax  mpg  engineSize  model_num  model_A1 \
3      2017 12500  15735  150  55.4          1.4          0      True
4      2017 16800  25952  145  67.3          2.0          3     False
10     2019 17300   1998  145  49.6          1.0          2     False
11     2017 16100  28955  145  58.9          1.4          2     False
11     2016 16500  52198  125  57.6          2.0          5     False
...     ...   ...     ...   ...   ...         ...         ...     ...
10663  2020 16999   4018  145  49.6          1.0          2     False
10664  2020 16999   1978  150  49.6          1.0          2     False
10665  2020 17199    609  150  49.6          1.0          2     False
10666  2017 19499   8646  150  47.9          1.4          9     False
10667  2016 15999  11855  150  47.9          1.4          9     False

      model_A3  model_A4  ...  model_Q2  model_Q3  model_Q5  model_RS3 \
0      False   False   ...    False    False    False    False
3      False   True    ...    False    False    False    False
4      True    False   ...    False    False    False    False
10     True    False   ...    False    False    False    False
11     False   False   ...    False    False    False    False
...     ...     ...     ...     ...     ...     ...     ...
10663  True    False   ...    False    False    False    False
10664  True    False   ...    False    False    False    False
10665  True    False   ...    False    False    False    False
10666  False   False   ...    False    True    False    False
10667  False   False   ...    False    True    False    False

      model_S3  transmission_Automatic  transmission_Manual \
0      False                                False          True
3      False                                True           False
4      False                                False          True
10     False                                False          True
11     False                                True           False
...     ...                             ...               ...
10663  False                                False          True
10664  False                                False          True
10665  False                                False          True
10666  False                                True           False
10667  False                                False          True

      transmission_Semi-Auto  fuelType_Diesel  fuelType_Petrol
0      False                  False           True
3      False                  True            False
4      False                  False           True
10     False                  False           True
11     False                  True            False
...     ...                   ...             ...
10663  False                  False           True
10664  False                  False           True
10665  False                  False           True
10666  False                  False           True
10667  False                  False           True

[6003 rows x 23 columns]
```

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Datenformatierung
 - Hohe Werte gehen stärker ein, eventuell Werte Normieren



Methode	Beschreibung	Gut geeignet für...	Empfindlich für Ausreißer?
Min-Max	Diese Methode skaliert die Werte so, dass sie zwischen 0 und 1 liegen:	Skalierung auf festen Bereich (z. B. NN)	Ja
Z-Score (Standardisierung)	Jeder Wert wird in Bezug auf den Mittelwert und die Standardabweichung skaliert.	Gut bei Daten mit Ausreißern oder wenn Normalverteilung angenommen wird, statistische Analysen, ML, Ausreißer vorhanden	Weniger

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation



Methode	Beschreibung	Gut geeignet für...	Empfindlich für Ausreißer?
Min-Max	Diese Methode skaliert die Werte so, dass sie zwischen 0 und 1 liegen:	Skalierung auf festen Bereich (z. B. NN)	Ja
Z-Score (Standardisierung)	Jeder Wert wird in Bezug auf den Mittelwert und die Standardabweichung skaliert.	Gut bei Daten mit Ausreißern oder wenn Normalverteilung angenommen wird, statistische Analysen, ML, Ausreißer vorhanden	Weniger

Werte	Min-Max	Z-Score (Werte zentriert um 0 mit Standardabweichung)
2900	2900 → 0.0	2900 → -1.14
3000	3000 → 0.33	3000 → -0.38
3100	3100 → 0.67	3100 → 0.38
3200	3200 → 1.0	3200 → 1.14

Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 4: Modeling

- Auswahl des Modells
 - Clustering (k-Means)
- Testmodell erstellen
 - Bspw. auf Basis eines Sample Datensatzes
- Modell anwenden
 - Bspw. auf einen vollständigen Datensatz (sofern mit Sample oder Trainingsdaten gearbeitet wurde)



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 4: Modeling

- Modell anwenden
 - Bspw. auf einen vollständigen Datensatz (sofern mit Sample oder Trainingsdaten gearbeitet wurde)



	price	mileage	year	Cluster
0	12500	15735	2017	2
1	16500	36203	2016	0
2	11000	29946	2016	2
3	16800	25952	2017	2
4	17300	1998	2019	1

Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - Bspw. Silhouette Score
 - Misst, wie **nah ein Punkt an seinem eigenen Cluster** ist im Vergleich zu **anderen Clustern**.
→ Werte von **-1 (schlecht)** bis **+1 (perfekt)**.
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen



Daumenregel:

≥ 0.7 → sehr gut

$0.5-0.7$ → gut

$0.25-0.5$ → okay

< 0.25 → schwach

Silhouette Score: 0.451

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen

mileage						
	count	mean	std	min	25%	50%
Cluster						
0	1981.0	41140.576981	5984.882945	31447.0	36000.00	40494.0
1	3878.0	5569.076328	3780.598854	5.0	2891.50	5000.0
2	2861.0	22648.786788	5611.650425	8773.0	18200.00	22721.0
3	914.0	65116.806346	8479.267739	52561.0	57314.75	63992.0
4	313.0	100341.191693	19723.971084	82000.0	88000.00	95000.0
5	721.0	8375.790569	8114.563806	1.0	3000.00	6000.0

price						
	75%	max	count	mean	std	min
Cluster						
0	46048.00	55500.0	1981.0	16693.370015	5894.571212	5995.0
1	7600.75	22100.0	3878.0	27311.115523	5763.317344	11495.0
2	27427.00	33165.0	2861.0	18134.485844	4869.792617	4689.0
3	71990.00	83165.0	914.0	13470.594092	4820.233931	3888.0
4	107150.00	323000.0	313.0	8820.041534	3665.889548	1490.0
5	10342.00	40274.0	721.0	53154.235784	14582.162574	38799.0

year							
	25%	50%	75%	max	count	mean	std
Cluster							
0	12881.0	15990.0	18950.0	52000.0	1981.0	2015.612822	1.335611
1	22790.5	26990.0	31500.0	40000.0	3878.0	2018.900206	0.766594
2	14790.0	17950.0	20560.0	40000.0	2861.0	2016.570430	1.113028
3	10000.0	12699.5	15733.5	40990.0	914.0	2014.568928	1.898912
4	6490.0	8695.0	11000.0	25940.0	313.0	2012.440895	3.622913
5	44990.0	49750.0	55500.0	145000.0	721.0	2018.846047	1.036763

year					
	min	25%	50%	75%	max
Cluster					
0	2003.0	2015.0	2016.0	2016.0	2019.0
1	2014.0	2019.0	2019.0	2019.0	2020.0
2	2004.0	2016.0	2017.0	2017.0	2020.0
3	1998.0	2014.0	2015.0	2016.0	2018.0
4	1997.0	2010.0	2014.0	2015.0	2017.0
5	2013.0	2019.0	2019.0	2019.0	2020.0




Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation


- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen
 - Eine visuelle Auswertung der Attribute „year“ und „mileage“ zeigt deutlich die Aufteilung der verschiedenen Cluster



Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen




Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen

Die Kurve fällt am Anfang stark ab – je mehr Cluster, desto kleiner die Inertia. Ab einem bestimmten Punkt („Knick“ oder Elbow) bringt ein weiteres Erhöhen von k kaum noch Verbesserung. Dieser Knickpunkt ist die empfohlene Clusteranzahl.



Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 6: Deployment

- Zusammenfassender Bericht und Präsentation der Ergebnisse
- Implementierungsstrategie planen
 - Speichern der Cluster in neues .csv-file
- Überwachung der Gültigkeit der Modelle planen

	price	mileage	year	Cluster
1	12500	15735	2017	2
2	16500	36203	2016	0
3	11000	29946	2016	2
4	16800	25952	2017	2
5	17300	1998	2019	1
6	13900	32260	2016	0
7	13250	76788	2016	3
8	11750	75185	2016	3
9	10200	46112	2015	0
10	12000	22451	2016	2
11	16100	28955	2017	2
12	16500	52198	2016	0
13	17000	44915	2016	0
14	16400	21695	2017	2
15	15400	47348	2015	0
16	14500	26156	2017	2
17	15700	28396	2016	2
18	13900	30516	2014	2
19	19000	37652	2016	0



1. Was ist die Elbow Methode?
2. Was ist ein Dendrogramm?
3. Welchen Einfluss haben folgende Bedingungen auf die Modellierung :
 1. Skalenniveau
 2. Fehlende Werte
 3. Doppelte Werte
 4. Ausreißer
4. Mit welchen Mitteln kann den oben genannten Einflüsse begegnet werden?

Cluster-Analyse

25 Minuten Zeit



Aufgabe:

1. Findet euch in euren **Teams aus 2 Personen** zusammen.
2. Arbeitet als Team im Sinne des “Extreme Programming” (XP) nach der Kernpraktik “Pair Programming”
3. Erweitert auf Basis einer der Datensätze zu Gebrauchtfahrzeugen “**used_car.csv**“ euer Notebook mit Informationen zu den folgenden CRISP-DM Phasen:
 - Data Preparation (Transformationen für das Modell)
 - Modeling (Clustering Methode, um Gruppen in den Daten zu identifizieren)
 - Evaluation
 - Deployment (in neues .csv-file mit Cluster speichern)

Ihr könnt euch an dem Beispiel aus dem Notebook „uc_cluster_analysis_CRISP-DM.ipynb“ orientieren.



Methoden und Anwendungen Künstlicher Intelligenz (KI)


Lernziele



Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- Wie sich **Analysemethoden** nach **Art de Komplexität** unterscheiden lassen
- was das **Grundprinzip der Clusteranalyse** ist und wie sich dieses **Anwenden** lässt
- was das **Grundprinzip der Assoziationsanalyse** ist und wie sich dieses **Anwenden** lässt

ANALYTICS-VERFAHREN VERWENDUNGSZWECK




Quelle Grafik: Gluchowski, Schieder, Chamoni 2021 nach Dorschel 2015.

Zuordnung von Objekten in undefinierte Gruppen (ohne Label Attribut) „Unüberwachtes Lernen“

Auffinden von statistischen Zusammenhängen (Assoziation) zwischen verschiedenen Objekten in einem Datensatz. Ableitung von signifikanten Assoziationsregeln.

Zuordnung von Objekten in zuvor definierte Klassen (basierend auf Beispieldatensätzen mit Label Attribut) „Überwachtes Lernen“ (mit Training- und Test-Datensatz)



„Assoziationsanalysen widmen sich der Fragestellung, welche Ereignisse häufig parallel oder mit zeitlichem Versatz auftreten.“

(Gluchowski, ,Schieder, Chamoni, 2012, S. 43)

- **Parallele Assoziation**

Gleichzeitige Ereignisse, wie zwei Artikel in einem Warenkorb.

- **Sequenzielle Assoziation**

Ereignisse die zeitlich versetzt stattfinden, obwohl zwischen den Ereignissen ein Zusammenhang existiert


Jeder Messwert kann als Item gesehen werden. Items treten als Elemente von Mengen (bspw. Artikel in einem Warenkorb) oder als einzelne Attributwerte von Datensätzen (bspw. Name, Wohnort) auf, sogenannte Itemsets.

ASSOZIATIONSANALYSE

BEISPIEL

- **Ziel:** Assoziationen zwischen Attributen oder Elementen ableiten
- **Support**
Relative Häufigkeit, in denen die **Regel zutrifft**
Dies kommt in y Prozent der Gesamtfälle vor
Beispiel:
Käse und Wein / Alle Warenkörbe
 $5.000 / 100.000 = 5 \%$
=> Bei 5 % aller Einkäufe wird Käse und Wein zusammen gekauft!
- **Konfidenz**
Relative Häufigkeit, in denen die **Regel anwendbar** ist
Wenn Item A vorliegt (Prämisse), dann tritt in x Prozent der Fälle auch Item B auf (Konklusion)
Beispiel:
Käse und Wein / Käse
 $5.000 / 20.000 = 25\%$
=> Bei 25 % der Käufe von Käse wird auch Wein dazu gekauft!

Potenziell **interessante Regeln** bieten mehr als einen minimalen Support und eine minimale Konfidenz.



Quelle Grafik: Nach Gluchowski, Schieder, Chamoni 2021, S. 44.

Anwendungsbeispiel

Assoziationen von Attributen für Gebrauchtwagen


Szenario:

Ein Gebrauchtwagenhändler (GWH) hat viele Daten über gebrauchte Fahrzeuge gesammelt. Er möchte herausfinden, ob es **Assoziationen von Attributen** in den Daten gibt.

Ziel: Identifizierung von Assoziationen von Attributen von Gebrauchtwagen

Vorgehen nach dem CRISP-DM Prozess in 6 Schritten:

1. Business Understanding (Aufgabendefinition)
2. Data Understanding (Auswahl der relevanten Datenbestände)
3. Data Preparation (Datenaufbereitung)
4. Modeling (Auswahl und Anwendung von Modellen)
5. Evaluation (Bewertung und Interpretation der Ergebnisse)
6. Deployment (Anwendung der Ergebnisse)



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Daten beschreiben

(10668, 9)

```
Index(['model', 'year', 'price', 'transmission', 'mileage', 'fuelType', 'tax',  
      'mpg', 'engineSize'],  
      dtype='object')
```

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	A1	2017	12500	Manual	15735	Petrol	150	55.4	1.4
1	A6	2016	16500	Automatic	36203	Diesel	20	64.2	2.0
2	A1	2016	11000	Manual	29946	Petrol	30	55.4	1.4
3	A4	2017	16800	Automatic	25952	Diesel	145	67.3	2.0
4	A3	2019	17300	Manual	1998	Petrol	145	49.6	1.0

	year	price	mileage	tax	mpg	engineSize
count	10668.000000	10668.000000	10668.000000	10668.000000	10668.000000	10668.000000
mean	2017.100675	22896.685039	24827.244001	126.011436	50.770022	1.930709
std	2.167494	11714.841888	23505.257205	67.170294	12.949782	0.602957
min	1997.000000	1490.000000	1.000000	0.000000	18.900000	0.000000
25%	2016.000000	15130.750000	5968.750000	125.000000	40.900000	1.500000
50%	2017.000000	20200.000000	19000.000000	145.000000	49.600000	2.000000
75%	2019.000000	27990.000000	36464.500000	145.000000	58.900000	2.000000
max	2020.000000	145000.000000	323000.000000	580.000000	188.300000	6.300000


```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 10668 entries, 0 to 10667  
Data columns (total 9 columns):  
#   Column          Non-Null Count  Dtype  
---  ---  
0   model           10668 non-null  object  
1   year            10668 non-null  int64  
2   price           10668 non-null  int64  
3   transmission    10668 non-null  object  
4   mileage         10668 non-null  int64  
5   fuelType        10668 non-null  object  
6   tax             10668 non-null  int64  
7   mpg             10668 non-null  float64  
8   engineSize      10668 non-null  float64  
dtypes: float64(2), int64(4), object(3)  
memory usage: 750.2+ KB
```

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Auswahl der Daten
 - Für die Assoziations-Analyse müssen einzelne, zählbare Ausprägungen der Attribute vorliegen (Binäres Format, Numerische Werte sind eher ungeeignet, Kategoriale Werte müssen transformiert werden)
- Bereinigung der Daten
 - Fehlende Werte entfernen oder Ersetzen
 - Duplikate entfernen
 - Evtl. Ausreißer ausschließen
- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig von dem Skalenniveau
 - Numerische Skalen transformieren oder ausschließen
- Datenformatierung
 - Hohe Werte gehen stärker ein, eventuell Werte Normieren



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Assoziationen von Attributen für Gebrauchtwagen

Schritt 3: Data Preparation

- Auswahl der Daten



	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	A1	2017	12500	Manual	15735	Petrol	150	55.4	1.4
1	A6	2016	16500	Automatic	36203	Diesel	20	64.2	2.0
2	A1	2016	11000	Manual	29946	Petrol	30	55.4	1.4
3	A4	2017	16800	Automatic	25952	Diesel	145	67.3	2.0
4	A3	2019	17300	Manual	1998	Petrol	145	49.6	1.0

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten



Schritt 3: Data Preparation

- Bereinigung der Daten
 - Fehlende Werte entfernen oder Ersetzen
 - Duplikate entfernen
 - Evtl. Ausreißer ausschließen
- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig von dem Skalenniveau
 - Numerische Skala in Gruppen transformieren (niedrig, mittel, hoch)
 - In binäres Format umwandeln (One-Hot Encoding)
- Datenformatierung
 - ...

Price in Gruppen

```
0      niedrig
1      niedrig
2      niedrig
3      niedrig
4      mittel
...
10663   mittel
10664   mittel
10665   mittel
10666   mittel
10667   niedrig
Name: price_group, Length: 10668, dtype: category
Categories (3, object): ['niedrig' < 'mittel' < 'hoch']
```

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten



Schritt 3: Data Preparation

- Bereinigung der Daten
 - Fehlende Werte entfernen oder Ersetzen
 - Duplikate entfernen
 - Evtl. Ausreißer ausschließen
- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig von dem Skalenniveau
 - Numerische Skala in Gruppen transformieren (bspw. niedrig, mittel, hoch)
 - In binäres Format umwandeln (One-Hot Encoding)
- Datenformatierung
 - ...

Year als Gruppen

```
0      2017
1      2016
2      2016
3      2017
4      2019
...
10663  2020
10664  2020
10665  2020
10666  2017
10667  2016
Name: year_group, Length: 10668, dtype: category
Categories (5, object): ['2016' < '2017' < '2018' < '2019' < '2020']
```

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Bereinigung der Daten
 - Fehlende Werte entfernen oder Ersetzen
 - Duplikate entfernen
 - Evtl. Ausreißer ausschließen
- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig von dem Skalenniveau
 - Numerische Skala in Gruppen transformieren (niedrig, mittel, hoch)
 - In binäres Format umwandeln (One-Hot Encoding)
- Datenformatierung
 - ...

```
price_group_niedrig price_group_mittel price_group_hoch model_A1 \
0 True False False True
1 True False False False
2 True False False True
3 True False False False
4 False True False False
...
10663 False True False False
10664 False True False False
10665 False True False False
10666 False True False False
10667 True False False False

model_A2 model_A3 model_A4 model_A5 model_A6 model_A7 ... \
0 False False False False False False ...
1 False False False False True False ...
2 False False False False False False ...
3 False False True False False False ...
4 False True False False False False ...
...
10663 False True False False False False ...
10664 False True False False False False ...
10665 False True False False False False ...
10666 False False False False False False ...
10667 False False False False False False ...

year_group_2017 year_group_2018 year_group_2019 year_group_2020 \
0 True False False False
1 False False False False
2 False False False False
3 True False False False
4 False False True False
...
10663 False False False True
10664 False False False True
10665 False False False True
10666 True False False False
10667 False False False False

transmission_Automatic transmission_Manual transmission_Semi-Auto \
0 False True False False
1 True False False False
2 False True False False
3 True False False False
4 False True False False
...
10663 False True False False
10664 False True False False
10665 False True False False
10666 True False False False
10667 False True False False

fuelType_Diesel fuelType_Hybrid fuelType_Petrol
0 False False True
1 True False False
2 False False True
3 True False False
4 False False True
...
10663 False False True
10664 False False True
10665 False False True
10666 False False True
10667 False False True

[10668 rows x 40 columns]
```

Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 4: Modeling

- Auswahl des Modells
 - Apriori Assoziationsanalyse
- Testmodell erstellen
 - Bspw. auf Basis eines Sample Datensatzes
- Modell anwenden
 - Bspw. auf einen vollständigen Datensatz (sofern mit Sample oder Trainingsdaten gearbeitet wurde)



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen



Schritt 5: Evaluation

- Bewertung des Modells

Bei Support von 0,5 ergibt sich 1 itemset (0 Regeln)

Bei Support von 0,4 ergeben sich 3 itemsets (0 Regeln)

Bei Support von 0,3 ergeben sich 8 itemsets (0 Regeln)

Bei Support von 0,2 ergeben sich 16 itemsets (3 Regeln)

- Bewertung der Resultate
- Bewertung des Prozesses
- Nächste Schritte festlegen

	support	itemsets
0	0.522778	(fuelType_Diesel)

	support	itemsets
0	0.409543	(transmission_Manual)
1	0.522778	(fuelType_Diesel)
2	0.474597	(fuelType_Petrol)

	support	itemsets
0	0.335583	(price_group_niedrig)
1	0.335208	(price_group_mittel)
2	0.329209	(price_group_hoch)
3	0.370829	(year_group_2016)
4	0.409543	(transmission_Manual)
5	0.336614	(transmission_Semi-Auto)
6	0.522778	(fuelType_Diesel)
7	0.474597	(fuelType_Petrol)

	support	itemsets
0	0.335583	(price_group_niedrig)
1	0.335208	(price_group_mittel)
2	0.329209	(price_group_hoch)
3	0.370829	(year_group_2016)
4	0.299681	(year_group_2019)
5	0.253843	(transmission_Automatic)
6	0.409543	(transmission_Manual)
7	0.336614	(transmission_Semi-Auto)
8	0.522778	(fuelType_Diesel)
9	0.474597	(fuelType_Petrol)
10	0.262373	(price_group_niedrig, year_group_2016)
11	0.245876	(price_group_niedrig, transmission_Manual)
12	0.201069	(price_group_hoch, year_group_2019)
13	0.210724	(transmission_Manual, year_group_2016)
14	0.238751	(fuelType_Diesel, year_group_2016)
15	0.210911	(transmission_Manual, fuelType_Petrol)

Begriff	Bedeutung
Support	Wie oft kommt Regel im gesamten Datensatz vor
Confidence	Wie oft stimmt Regel, wenn Bedingung zutrifft
Lift	Verhältnis zu zufälliger Wahrscheinlichkeit (>1 gut)

Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung der Resultates
 - Minimum Support: 0.2
 - Support = Transaktionen mit X und Y / alle Transaktionen
 - Minimum Confidence: 0.7
 - Konfidenz = Support (X, Y) / Support (X)
- Gefundene Regeln:
 1. Wenn niedrige Preisgruppe => Jahr 2016 (Support: 26 %)
In 78 % der Fälle, in denen eine niedrige Preisgruppe vorliegt, handelte es sich um ein Fahrzeug aus dem Jahr 2016. Der Lift von 2,10 zeigt, dass dies häufiger passiert als zufällig erwartet.
 2. Wenn Jahr 2016 => niedrige Preisgruppe (Support 26 %)
In 70 % der Fälle, in denen ein Fahrzeug aus dem Jahr 2016 vorliegt, handelte es sich um ein Fahrzeug aus der neidrigen Preisgruppe. Der Lift von 2,10 zeigt, dass dies häufiger passiert als zufällig erwartet.
 3. Wenn niedrige Preisgruppe => Manuelles Getriebe (Support 24 %)
In 73 % der Fälle, in denen eine niedrige Preisgruppe vorliegt, handelte es sich um ein Fahrzeug mit manuellem Getriebe. Der Lift von 1,78 zeigt, dass dies häufiger passiert als zufällig erwartet.

	antecedents	consequents	support	confidence	lift
0	(price_group_niedrig)	(year_group_2016)	0.262373	0.781844	2.108369
1	(year_group_2016)	(price_group_niedrig)	0.262373	0.707533	2.108369
2	(price_group_niedrig)	(transmission_Manual)	0.245876	0.732682	1.789024

	support	itemsets
0	0.335583	(price_group_niedrig)
1	0.335208	(price_group_mittel)
2	0.329209	(price_group_hoch)
3	0.370829	(year_group_2016)
4	0.299681	(year_group_2019)
5	0.253843	(transmission_Automatic)
6	0.409543	(transmission_Manual)
7	0.336614	(transmission_Semi-Auto)
8	0.522778	(fuelType_Diesel)
9	0.474597	(fuelType_Petrol)
10	0.262373	(price_group_niedrig, year_group_2016)
11	0.245876	(price_group_niedrig, transmission_Manual)
12	0.201069	(price_group_hoch, year_group_2019)
13	0.210724	(transmission_Manual, year_group_2016)
14	0.238751	(fuelType_Diesel, year_group_2016)
15	0.210911	(transmission_Manual, fuelType_Petrol)

Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen



Schritt 5: Evaluation

- Bewertung des Modells
- Bewertung der Resultate
- Bewertung des Prozesses
 - Prozess und Transformation der Daten ist von der Komplexität her noch überschaubar
- Nächste Schritte festlegen
 - Weitere Transformationen (Bildung von Teilmengen) oder Hinzunahme von Attributen möglich
 - Ergebnisse zeigen ersten Zusammenhang zwischen Preis-Gruppe und Jahres-Gruppe des Fahrzeuges sowie niedriger Preisgruppe und manueller Getriebeart
 - Könnte in fortgeschrittener Analyse weiter untersucht werden

Assoziationsanalyse

Übungsfragen



1. Was wird unter einer Assoziationsanalyse verstanden?
2. Was ist bei den Daten für die Apriori-Methode zu beachten?
3. Beschreibe mit eigenen Worten die Begriffe:
 - Support
 - Confidence

Assoziationsanalyse

25 Minuten Zeit



Aufgabe:

1. Findet euch in euren **Teams aus 2 Personen** zusammen.
2. Arbeitet als Team im Sinne des “Extreme Programming” (XP) nach der Kernpraktik “Pair Programming”
3. Erstellt auf Basis einer der Datensätze zu Gebrauchtfahrzeugen “**used_car.csv**“ ein Notebook mit Informationen zu den folgenden CRISP-DM Phasen:
 - Data Preparation (Transformationen für das Modell)
 - Modeling (Assoziationsalgorithmus, bspw. Apriori)
 - Evaluation

Ihr könnt euch an dem Beispiel aus dem Notebook „uc_association_analysis_CRISP-DM.ipynb“ orientieren.

