

06

MASCHINELLES LERNEN, KLASSIFIKATION UND KÜNSTLICHE NEURONALE NETZE (KNN)

KURSinHALTE UND TERMINE

Kursinhalte

Data Science	1
Statistische Grundlagen	2
Softwareentwicklung	3
Analysemethoden, Clustering und Assoziationen	4
Grundlagen Künstlicher Intelligenz (KI)	5
Maschinelles Lernen, Klassifikation und Künstliche Neuronale Netze (KNN)	6
Testing / Integration / Deployment	7
Anwendungen Künstlicher Intelligenz (KI)	8
Zusammenfassung / Fragen / Klausurvorbereitung	9

Termine

#	Wochentag	Datum	von - bis	Räume
1	Freitag	04.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
2	Freitag	11.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.27 Bothfeld
3	Freitag	25.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
4	Freitag	16.05.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
5	Freitag	23.05.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
6	Freitag	06.06.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
7	Freitag	20.06.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
8	Freitag	04.07.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
9	Freitag	11.07.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt

Methoden und Anwendungen Künstlicher Intelligenz (KI)

Lernziele

Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich **maschinelles Lernen** als **Teilgebiet** der **Künstlichen Intelligenz** einordnen lässt
- was das **Grundprinzip der Klassifikation** ist, wie dieses **angewendet** werden kann und wie sich die folgenden Methoden unterscheiden:
 - **Entscheidungsbaum**
 - **Support Vector Machine (SVM)**
- was **Künstliche Neuronale Netze (KNN)** sind, wie diese **angewendet** werden können und wie sich die Folgenden unterscheiden:
 - **Perzeptron**
 - **Back-Propagation-Netz**
 - **Hopfield-Netz**



ABGRENZUNG VERWANDTER FACHGEBIETE

ERSTE GROBE EINORDNUNG

– Data Science

Die Wissenschaft „Data Science“, ein Fachgebiet der Informatik, beschäftigt sich mit der Extraktion von Wissen aus den Informationen in Daten. Da es immer mehr Daten mit Informationen gibt, kann auch immer mehr Wissen aus den Informationen der Daten abgeleitet werden.

– Künstliche Intelligenz


Dabei setzt „Künstliche Intelligenz“ intelligentes Verhalten in Algorithmen um, mit der Zielsetzung, automatisiert „menschenähnliche Intelligenz“ so gut wie möglich nachzubilden

– Maschinelles Lernen

Mithilfe der Algorithmen des maschinellen Lernens werden mit vorhandenen Datenbeständen Muster und Gesetzmäßigkeiten erkannt und verallgemeinert, um damit neue Problemlösungen umzusetzen. In Lernphasen lernen entsprechende ML-Algorithmen, aus vielen diversen Beispielen simple Muster und Strukturen, hin zu komplexen Merkmalen und Gesetzmäßigkeiten zu erkennen.

– Deep Learning

Deep Learning ist eine Spezialisierung des maschinellen Lernens und nutzt vorwiegend künstliche neuronale Netze (KNN).



Quelle: Künstliche Intelligenz, Prof. Norbert Pohlmann

Quellen: <https://norbert-pohlmann.com/glossar-cyber-sicherheit/kuenstliche-intelligenz/>

MASCHINELLES LERNEN

„**Artificial Intelligence** is the study of how to make computers do things, at which, at the moment, people are better.“ (Elaine Rich, 1983)

- Orientiert man sich an der Definition von KI nach Elaine Rich und bedenkt dass Computer uns Menschen bezüglich der **Lernfähigkeit** weit unterlegen sind, dann folgt daraus, dass die Erforschung der **Mechanismen des Lernens** und Entwicklung **maschineller Lernverfahren** ein wichtiges Teilgebiet für die KI darstellt. (vgl. W. Ertel, 2025.)
- Aus Sicht des **Software-Entwicklers** entsteht ebenfalls eine Forderung nach **maschinellen Lernverfahren**, bspw. für die Programmierung des **Verhaltens autonomer Roboter**. (nicht alle zukünftigen Situationen können vorhergesehen werden, nicht alle Lösungen können vorab programmiert werden)
- Häufig kommt eine Mischung aus **programmiertem** und **gelerntem Verhalten** zum Einsatz.



Was ist **Lernen**?

- Das „**Auswendiglernen**“ von Vokabeln ist für viele Menschen schwierig, für einen Computer jedoch ganz einfach (Text in Datei speichern und bei Bedarf abrufen) und somit für die KI recht uninteressant.
- Das **Lernen mathematischer Fertigkeiten** (bspw. Addieren) erfolgt hingegen nicht durch Auswendiglernen. Es wäre hierbei auch unmöglich alle denkbaren Kombinationen von Werten zu speichern.

Wie **lernen wir** also Mathematik?

- Der Lehrer **erklärt das Verfahren** und die Schüler **üben anhand von Beispielen**, solange bis sie anhand von neuen **Beispielen** keine **Fehler** mehr machen.
- Falls der Schüler das **Verfahren** anhand von 50 **Beispielen** verstanden hat, kann er das gelernte Verfahren dann **auf unendlich viele neue Beispiele** anwenden.
- Diesen Vorgang nennt man **Generalisierung**.



MASCHINELLES LERNEN

HAUPTTYPEN DES LERNENS

1. „Überwachtes Lernen“ (supervised learning)

Überwachtes Lernen ist ein maschinelles Lernverfahren, bei dem ein **Modell** aus einem **Trainingsdatensatz** lernt, der **Eingabedaten** (Features) und zugehörige **Zielwerte** (Labels) enthält. Ziel ist es, eine Funktion zu erlernen, die neue, unbekannte Daten korrekt vorhersagen kann (bspw. bei der Klassifikation oder Regression).

2. „Unüberwachtes Lernen“ (unsupervised learning)

Beim unüberwachten Lernen wird ein **Modell** mit **Eingabedaten** trainiert, die **keine zugehörigen Zielwerte** enthalten. Ziel ist es, Strukturen oder Muster in den Daten zu erkennen (z. B. Clusterbildung, Dimensionsreduktion).

3. „Bestärkendes Lernen“ (reinforcement learning)

Reinforcement Learning ist ein Lernparadigma, bei dem ein Agent durch Interaktion mit einer Umgebung lernt, **Aktionen** so **auszuwählen**, dass er eine möglichst hohe kumulierte **Belohnung** erhält. Der Agent entscheidet letztlich darüber, welche **Aktion** im Vorfeld primär für die **Verstärkung** verantwortlich war, sodass er seine **Aktionen ändern** kann (bspw. Spielstrategie für Schach und oder in der Robotik)





1. Erläutere anhand der folgenden Lernverfahren wie Menschen lernen:
 - **Auswendiglernen**
 - **Erlernen von Verfahren**
2. Erkläre die Funktionsweise der drei Haupttypen des maschinellen Lernens:
 - **Überwachtes Lernen**
 - **Unüberwachtes Lernen**
 - **Bestärkendes Lernen**
3. Warum ist die **Erforschung maschinellen Lernens** von Relevanz?

Methoden und Anwendungen Künstlicher Intelligenz (KI)


Lernziele



Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich **maschinelles Lernen** als **Teilgebiet** der **Künstlichen Intelligenz** einordnen lässt
- was das **Grundprinzip der Klassifikation** ist, wie dieses **angewendet** werden kann und wie sich die folgenden Methoden unterscheiden:
 - **Entscheidungsbaum**
 - **Support Vector Machine (SVM)**
- was **Künstliche Neuronale Netze (KNN)** sind, wie diese **angewendet** werden können und wie sich die Folgenden unterscheiden:
 - **Perzeptron**
 - **Back-Propagation-Netz**
 - **Hopfield-Netz**

ANALYTICS-VERFAHREN VERWENDUNGSZWECK



Quelle Grafik: Gluchowski, Schieder, Chamoni 2021 nach Dorschel 2015.


Zuordnung von Objekten in undefinierte Gruppen (ohne Label Attribut) „Unüberwachtes Lernen“

Auffinden von statistischen Zusammenhängen (Assoziation) zwischen verschiedenen Objekten in einem Datensatz. Ableitung von signifikanten Assoziationsregeln.

Zuordnung von Objekten in zuvor definierte Klassen (basierend auf Beispieldatensätzen mit Label Attribut) „Überwachtes Lernen“ (mit Training- und Test-Datensatz)

KLASSIFIKATION

„Klassifikation ist ein überwachtes Lernverfahren, das markierte Daten verwendet, um Objekte zu Klassen zuzuordnen“ (Runkler 2015, S.89)



KLASSIFIKATION METHODEN

Häufig verwendete Methoden für die Klassifikation:

- **Naiver Bayes-Klassifikator**

Probabilistisches Verfahren, das auf dem Satz von Bayes basiert

- **Lineare Diskriminanzanalyse**

Effiziente Methode, die sich auch für korrelierte Merkmale eignet, setzt jedoch eine näherungsweise Gauß-Verteilung der Merkmale voraus

- **Supportvektormaschine**

Kann nichtlineare Klassengrenzen finden, hat jedoch einen relativ hohen Rechenaufwand um ein großes Optimierungsproblem unter Nebenbedingungen zu lösen

- **Nächster-Nachbar-Klassifikator**


Kein Lernaufwand in der Trainingsphase, es können Trainingsdaten ergänzt werden und nichtlineare Klassengrenzen gefunden werden. Recht hoher Rechenaufwand

- **Lernende Vektorquantifizierung**

Effizienter als Nächste-Nachbar-Klassifikator, mitunter längere Trainingsphase

- **Entscheidungsbaum**

- Liefert Information über Reihenfolge der Wichtigkeit von Merkmalen, nicht alle Merkmale müssen verwendet werden, vorwiegend auf diskrete Merkmale ausgelegt.



Quelle: Runkler, 2015, S. 93

KLASSIFIKATION

Typische **Klassifikationsaufgabe**:

- Sortiere **Gebrauchtwagen** aufgrund der **Länge (in cm)** und der **Anzahl Sitze (Zahl)** automatisch in eine **Fahrzeugklasse** ein.
- „**Systeme** die in der Lage sind, **Merkmalsvektoren** in eine **endliche Anzahl von Klassen** einzuteilen werden **Klassifizierer** genannt.“ (W. Ertel, 2025)
- Zur **Einstellung des Systems** werden **Gebrauchtwagen** durch einen **Experten** einer **Klasse zugeordnet**. Dabei werden die Messwerte für **Länge** und **Anzahl Sitze** zusammen mit der **Klasse** aufgenommen.
- Die Aufgabe des **maschinellen Lernens** besteht nun darin, aus den gesammelten Daten eine **Funktion zu generieren**, die für **Gebrauchtwagen** anhand der zwei Merkmale **Länge** und **Anzahl Sitze** die richtige **Klasse** bestimmt.
- Deutlich **schwieriger** wird es, wenn die zu klassifizierenden Objekte nicht durch zwei, sondern durch **viele Merkmale** beschrieben werden!

Länge (cm)	Anzahl Sitze	Fahrzeugklasse
380	4	Kleinwagen
410	4	Kleinwagen
420	5	Kompaktklasse
450	5	Kompaktklasse
430	5	?

KLASSIFIKATION

„Ein **Agent** heißt **lernfähig**, wenn sich seine **Leistungsfähigkeit** auf **neuen, unbekannten Daten** im Laufe der Zeit (nachdem er viele Trainingsbeispiele gesehen hat) **verbessert** (gemessen auf einem geeigneten Maßstab).“ (W. Ertel, 2025, S. 207)

- In den **Trainingsdaten** (Erfahrung) steckt das **Wissen**, welches von dem Lernverfahren extrahiert werden soll. Es ist auf die **Auswahl** einer **repräsentativen Stichprobe** für die zu lernende Aufgabe zu achten!
- **Testdaten** sind wichtig, um zu evaluieren ob der trainierte Agent gut von den gelernten auf neue Daten generalisieren kann
- die **Generalisierungsfähigkeit** des Lernverfahrens auf unbekannten Daten, kann durch **Testdaten** überprüft werden.



Quelle: W. Ertel, Grundkurs Künstliche Intelligenz, 2025, S. 207.

Klassifikation

Übungsfragen



1. Erkläre das Grundprinzip der **Klassifikation**!
2. Welchem **Lerntyp** (überwachtem, unüberwachtes Lernen) ist die **Klassifikation** zuzuordnen?
3. Erkläre das **Prinzip** von **Trainings-** und **Testdaten** und wobei darauf zu **achten** ist!

Anwendungsbeispiel

Klassifizierung von Gebrauchtwagen


Szenario:

Ein Gebrauchtwagenhändler (GWH) hat viele Daten über gebrauchte Fahrzeuge gesammelt. Mittels geeigneter Analyse-Methoden soll aus diesen Daten ein Mehrwert generiert werden. Im ersten Schritt sollen Fahrzeuge einer von drei **Preisklassen** (**high, medium, low**) zugeordnet werden.

Ziel: Klassifizierung von Gebrauchtfahrzeugen durch Training und Validierung eines Entscheidungsbaumes

Vorgehen nach dem CRISP-DM Prozess in 6 Schritten:

1. Business Understanding (Aufgabendefinition)
2. Data Understanding (Datenverständnis / EDA)
3. Data Preparation (Datenaufbereitung)
4. Modeling (Auswahl und Anwendung von Modellen)
5. Evaluation (Bewertung und Interpretation der Ergebnisse)
6. Deployment (Anwendung der Ergebnisse)




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

CRISP-DM PHASEN UND AKTIVITÄTEN

Aufgabendefinition	Datenverständnis	Datenaufbereitung
Business Understanding	Data Understanding	Data Preparation
- Bestimmung der betriebswirtschaftlichen Problemstellung - Situationsbewertung - Bestimmung analytischer Ziele - Erstellung eines Projektplans	- Daten sammeln - Daten beschreiben - Untersuchung der Daten - Verifizierung der Datenqualität	- Auswahl der Daten - Bereinigung der Daten - Transformation und Integration der Daten - Daten-formatierung

Die Datenaufbereitung nimmt zwischen 40-70 % der Zeit in Anspruch


Quelle: Datenaufbereitung im Mining-Prozess - IBM Dokumentation



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

CRISP-DM PHASEN UND AKTIVITÄTEN

Modellierung	Bewertung	Anwendung
Modeling	Evaluation	Deployment
• Auswahl des Modells • Testmodell erstellen • Modell erstellen	• Bewertung des Modells • Bewertung der Resultate • Bewertung des Prozesses • Nächste Schritte festlegen	• Zusammenfassender Bericht und Präsentation der Ergebnisse • Implementierungsstrategie planen • Überwachung der Gültigkeit der Modelle planen




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 1: Business Understanding

- **Bestimmung der betriebswirtschaftlichen Problemstellung**
 - Ein Gebrauchtwagenhändler (GWH) möchte den Preis für verfügbare Gebrauchtwagen mittels eines Modells bestimmen. Bisher wird der Preis auf Basis der Erfahrungswerte der Mitarbeiter bestimmt. Der Preis soll für die Kunden und im Vergleich zum Markt akzeptabel sein und gleichzeitig eine hohe Marge für den Händler einbringen. Durch den Einsatz einer datenbasierten Entscheidungsunterstützung soll gezeigt werden, ob es Potenzial für höhere Margen gibt.
- **Situationsbewertung**
 - Der GWH hat Daten über verkaufte Gebrauchtwagen über die Plattform kaggle bezogen. Die Grundlage für eine Datenanalyse ist damit vorhanden. Der aktuelle Prozess ist stark von der Erfahrung der jeweiligen Mitarbeiter abhängig. Ein datenbasierter und systemgestützter Prozess könnte diese starke Abhängigkeit entlasten und die Mitarbeiter bei Ihren Entscheidungen unterstützen. Es besteht die Chance neue Erkenntnisse aus Daten zu erlangen und bisher ungenutzte Potenziale zu heben.
- **Bestimmung analytischer Ziele**
 - Zuordnung von Gebrauchtfahrzeugen zu einer von 3 Preisklassen auf Basis eines trainierten Entscheidungsbaumes.
- **Erstellung eines Projektplans**
 - Zusammenstellen eines Teams (Rollen, Verantwortungen festlegen)
 - Vorgehen nach den CRISP-DM (Phasen und Dauer planen)
 - Ergebnisse dem Auftraggeber präsentieren




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Daten sammeln
 - Die Daten wurden von kaggle bezogen:
<https://www.kaggle.com/datasets/adityadesai13/used-car-dataset-ford-and-mercedes/data>
- Daten beschreiben (siehe EDA)
- Untersuchung der Daten (siehe EDA)
- Verifizierung der Datenqualität




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 2: Data Understanding

- Verifizierung der Datenqualität
 - **Fehlende Werte**
 - Mit Wert belegen oder NA lassen oder Entfernen
 - Hier: Gute Datenqualität => keine fehlenden Werte
 - **Duplikate**
 - Analyse ob sinnvolle Duplikate oder Entfernen
 - Überschreiben oder bereinigten Datensatz verwenden
 - **Skalenniveau**
 - Skalenniveau bei Bedarf anpassen
 - bspw. mittels „Label Encoding“ oder „One-Hot-Encoding“
 - **Verteilung und Ausreißer**
 - Identifizieren
 - Gegebenenfalls Entfernen oder Normalisierung der Daten




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Auswahl der Daten
 - Für die **Entscheidungsbaum-Methode** sind **numerische** Daten vorgesehen
- Bereinigung der Daten
 - **Fehlende Werte** entfernen oder Ersetzen
 - **Duplikate** entfernen
 - Evtl. **Ausreißer** ausschließen
- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig von dem Skalenniveau
 - **Nominale Skalen** transformieren oder ausschließen
- Datenformatierung
 - Hohe Werte gehen stärker ein, eventuell **Werte Normieren**



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.


Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Auswahl der Daten
 - Für die Entscheidungsbaum-Methode sind nur **numerische Daten** vorgesehen
 - model, transmission, fuelType sind nicht metrisch und müssen transformiert oder ausgeschlossen werden!

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	A1	2017	12500	Manual	15735	Petrol	150	55.4	1.4
1	A6	2016	16500	Automatic	36203	Diesel	20	64.2	2.0
2	A1	2016	11000	Manual	29946	Petrol	30	55.4	1.4
3	A4	2017	16800	Automatic	25952	Diesel	145	67.3	2.0
4	A3	2019	17300	Manual	1998	Petrol	145	49.6	1.0



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation


- Bereinigung der Daten

- Fehlende Werte entfernen oder Ersetzen
- Duplikate entfernen
- Ausreißer ausschließen

```
model      0
year       0
price      0
transmission 0
mileage    0
fuelType   0
tax        0
mpg        0
engineSize 0
dtype: int64
```

```
Alle Duplikate (inkl. erstes Vorkommen):
  model year price transmission mileage fuelType tax mpg engineSize
231   Q3  2019  34485    Automatic      10   Diesel  145  47.1      2.0
273   Q3  2019  34485    Automatic      10   Diesel  145  47.1      2.0
277   Q5  2019  31998   Semi-Auto      100   Petrol  145  33.2      2.0
567   Q3  2015  13995     Manual     35446   Diesel  145  54.3      2.0
727   Q2  2019   22495     Manual     1000   Diesel  145  49.6      1.6
...   ...   ...   ...         ...     ...   ...   ...      ...
9524  Q5  2019  44990    Automatic      10   Diesel  145  36.2      2.0
9529  Q5  2019  44990    Automatic      10   Diesel  145  36.2      2.0
9549  Q3  2019  29995     Manual      10   Petrol  145  39.8      1.5
9550  Q3  2019  29995     Manual      10   Petrol  145  39.8      1.5
9597  Q3  2019   28490     Manual      10   Diesel  145  42.8      2.0

[185 rows x 9 columns]
```



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.



Anwendungsbeispiel

Analyse von Gebrauchtwagen Daten



Schritt 3: Data Preparation

- Bereinigung der Daten
 - Fehlende Werte entfernen oder Ersetzen
 - Duplikate entfernen
 - Ausreißer ausschließen
- Hier: Mehrere Ausreißer nach **IQR-Methode** entfernt bzw. in **dataframe „df_clean“**



Anwendungsbeispiel

Analyse von Gebrauchtwagendaten



Schritt 3: Data Preparation

- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig vom Skalenniveau der Attribute
 - Nominale Skalen transformieren oder ausschließen
- Hier Attribute model, transmission, fuel_type per **Label Encoding** in mehrere Klassen (1-5) transformiert (**dataframe df_encoded**)

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize	price_group
0	0	2017	12500	1	2349	1	150	55.4	1.4	1
3	2	2017	16800	0	3103	0	145	67.3	2.0	1
4	1	2019	17300	1	291	1	145	49.6	1.0	2
10	1	2017	16100	1	3292	1	145	58.9	1.4	1
11	4	2016	16500	0	4042	0	125	57.6	2.0	1

Anwendungsbeispiel


Identifizierung von Clustern für Gebrauchtwagen

Schritt 4: Modeling

- Auswahl des Modells
 - Es soll ein Modell zur Erklärung der abhängigen Attribute für die Vorhersage einer Zugehörigkeit zu einer Preisklasse erstellt werden. Ziel ist demnach ein prediktives Klassifikationsmodell.
 - [1.10. Decision Trees — scikit-learn 1.6.1 documentation](#)
- Testmodell erstellen
 - Bspw. auf Basis eines Sample Datensatzes
- Modell anwenden
 - Bspw. auf einen vollständigen Datensatz (sofern mit Sample oder Trainingsdaten gearbeitet wurde)



CHOOSING THE RIGHT ESTIMATOR




https://scikit-learn.org/stable/machine_learning_map.html

INFOS ZU METHODEN IN SCIKIT-LEARN

1.10. Decision Trees

Decision Trees (DTs) are a non-parametric supervised learning method used for [classification](#) and [regression](#). The goal is to create a model that predicts the value of a target variable by learning simple decision rules inferred from the data features. A tree can be seen as a piecewise constant approximation.

For instance, in the example below, decision trees learn from data to approximate a sine curve with a set of if-then-else decision rules. The deeper the tree, the more complex the decision rules and the fitter the model.



Methode

`fit(X, y)`

Beschreibung

Trainiert ein Modell anhand der Eingabedaten X und (bei überwachtem Lernen) der Zielwerte y.

`predict(X)`

Gibt Vorhersagen für neue Eingabedaten X basierend auf dem gelernten Modell zurück.

`transform(X)`

Wendet eine Transformation auf die Daten an (z. B. bei PCA oder Standardisierung).

`fit_transform(X)`

Kombination aus `fit()` und `transform()` – zuerst lernen, dann anwenden.

`score(X, y)`

Gibt eine Gütekennzahl (Accuracy, R^2 , etc.) für die Modellleistung zurück.

Datenart

Merkmalsmatrix X

Zielwerte y

Kategorische Daten

Fehlende Werte

Format

2D-Array oder `pandas.DataFrame` mit Form (n_samples, n_features)

1D-Array, `pandas.Series` oder Liste mit Länge n_samples (z. B. Klassenlabels)


Vorverarbeitung notwendig (z. B. mit `OneHotEncoder`, `LabelEncoder`)

Müssen behandelt werden (z. B. mit `SimpleImputer`)

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen

```

Making predictions for the following 5 cars:
  model  year  transmission  mileage  fuelType
0      0  2017             1   15735         1
3      2  2017             0   25952         0
4      1  2019             1    1998         1
10     1  2017             1   28955         1
11     4  2016             0   52198         0
The predictions are
[1.19407895 1.81012658 2.01148106 1.19407895 1.07253886]

```



Prediktion von Preisklassen!

Besser wäre Vorhersage von Preisen!

Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 4: Modeling

- Auswahl des Modells
 - Es soll ein Modell zur Erklärung der abhängigen Attribute für die Vorhersage einer Zugehörigkeit zu einer Preisklasse erstellt werden. Ziel ist demnach ein prediktives Klassifikationsmodell.
 - Verwendung von numerischen Preisen
 - [DecisionTreeRegressor — scikit-learn 1.6.1 documentation](#)
- Testmodell erstellen
 - Bildung von Training und Testdatensatz mit Test_Train_Split
- Modell anwenden
 - Auf einen vollständigen Datensatz (sofern mit Sample oder Trainingsdaten gearbeitet wurde)




Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen

Decision tree trained on used car features



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen

```

Making predictions for the following 5 cars:
  model  year  transmission  mileage  fuelType
0      0  2017             1    15735         1
3      2  2017             0    25952         0
4      1  2019             1     1998         1
10     1  2017             1    28955         1
11     4  2016             0    52198         0
The predictions are
[19325.96499176 19325.96499176 23030.58094145 19325.96499176
 19325.96499176]

```



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 5: Evaluation

- Bewertung des Modells
- **Mean Absolute Error (MAE)**
Durchschnittlicher absoluter Fehler
→ Einfach interpretierbar
- **Mean Squared Error (MSE)**
→ Quadratische Fehlerstrafe; empfindlich gegenüber Ausreißern
- **Root Mean Squared Error (RMSE)**
→ Quadratwurzel des MSE – gleiche Einheit wie Zielgröße
- **R² (Bestimmtheitsmaß)**
→ Gibt an, wie viel Varianz das Modell erklärt (zwischen 0 und 1, evtl. negativ bei schlechtem Modell)
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen

MAE:	2579.79
MSE:	12657929.74
RMSE:	3557.80
R ² :	0.74

- **MAE:** je kleiner, desto besser
- **RMSE:** erlaubt direkten Vergleich mit Zielwerten
- **R² nahe 1:** gutes Modell
- **R² < 0:** Modell schlechter als Durchschnittswert



Der *mittlere absolute Fehler* ist wie folgt definiert:

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{Y}_i - Y_i|,$$

wobei folgende Variablen Verwendung finden:

n : Anzahl der Vorhersagewerte

$\hat{Y}_i$: Vorhersagewerte


Y_i : Beobachtungswerte

Anwendungsbeispiel

Identifizierung von Clustern f

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
 - Bewertung der Resultate
 - ...
 - Bewertung des Prozesses
 - ...
 - Nächste Schritte festlegen
-
- Jeder Punkt entspricht einer Vorhersage
 - Die **rote gestrichelte Linie** zeigt perfekte Vorhersage ($y = x$)
 - Je näher die Punkte an der Linie liegen, desto besser



Anwendungsbeispiel

Identifizierung von Clustern für Gebrauchtwagen

Schritt 6: Deployment

- Zusammenfassender Bericht und Präsentation der Ergebnisse
- Implementierungsstrategie planen
 - Ergebnisse und Abweichungen in csv-Datei schreiben
 - Optional: Modellvergleich erstellen
- Überwachung der Gültigkeit der Modelle planen




```
Decision Tree → R²: 0.813 | RMSE: 3557.798  
Random Forest → R²: 0.844 | RMSE: 3557.798  
Linear Regression → R²: 0.647 | RMSE: 3557.798
```

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 6: Deployment

- Zusammenfassender Bericht und Präsentation der Ergebnisse
 - Die Ergebnisse wurden dem Auftraggeber in Form einer Power-Präsentation vorgetragen und offene Fragen diskutiert. Die Dokumentation der Präsentation, des Analyseprozesses und der Ergebnisse erhält der Auftraggeber im Nachgang.
- Implementierungsstrategie planen
 - Des erstellte Modell wurde anhand eines bereitgestellten Datensatzes trainiert, angewendet und validiert. Um das Modell auf neue, bisher nicht betrachtete Datensätze anzuwenden, wird empfohlen das Modell mit tagesaktuellen Daten aus dem System des GWH neu zu beladen. Ein solcher Prozess ließe sich über einen Datenimport oder eine Anbindung an eine Datenbank oder einen Cloud-Speicher abbilden.
- Überwachung der Gültigkeit der Modelle planen
 - Durch die Verwendung neuer, bisher nicht bekannter Daten, kann die Qualität des Modells variieren. Das Modell wurde mit einem Trainingsdatensatz trainiert. Damit das Modell weiterhin gute Prognosen stelle, ist eine regelmäßige Überwachung (Monitoring) des Prozesses einzurichten sowie die Güte des Modells in regelmäßigen Abschnitten zu validieren.
 - Limitierung: Die Preise unterliegen am Markt äußeren Einflüssen (Inflation, politische Rahmenbedingungen, etc.), die in dem Modell zurzeit keine Berücksichtigung finden!



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Klassifikation / Regression

25 Minuten Zeit



Aufgabe:

1. Findet euch in euren **Teams aus 2 Personen** zusammen.
 2. Erstellt für den Datensatz zu Gebrauchtfahrzeugen eurer Automarke ein Notebook für eine Klassifikation / Regression zu den folgenden CRISP-DM Phasen:
 - **(Business Understanding)**
 - **(Data Understanding / EDA)**
 - **Data Preparation** (Transformationen für das Modell)
 - **Modeling** (Klassifizierungsalgorithmus, bspw. DecisionTree)
 - **Evaluation** (Bewertung und Interpretation der Ergebnisse)
 - **Deployment** (Anwendung der Ergebnisse)
- **Tipp:** Wählt die für eine Klassifizierung nötigen Daten aus der Datenmenge aus. Berücksichtigt bereits bestehende Strukturen wie vorhandene Klassen im Datensatz. Bestimmt, sofern benötigt, einzelne Rollen von Attributen (Label) und teilt den Datensatz in Trainings- und Testdaten auf. Transformiert die Daten in ein geeignetes Datenformat, dass von einer Klassifizierungsmethode verarbeitet werden kann. Wählt eine Klassifizierungsmethode aus (bspw. Entscheidungsbaum). Modelliert den kompletten Prozess. Achtet darauf, dass das Modell nicht nur erzeugt wird, sondern es auch auf einen Datensatz angewendet und das Ergebnis gespeichert wird!
- Ihr könnt euch an dem Beispiel aus dem Notebook „**uc_decision_tree_analysis_CRISP-DM.ipynb**“ orientieren.



Data Science Software Engineering

Teams

o3

1. Rudi
2. Krzysztof

mercedes

Hagenberg

1. Patryk
2. Tobias

ford

Housing Hackers

1. Manuel
2. Tijana



kodo no timu

1. Sascha
2. Jeremy

toyota

CodeJettters

1. Vincent
2. Cynthia

bwm



hyundai

Methoden und Anwendungen Künstlicher Intelligenz (KI)


Lernziele



Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich **maschinelles Lernen** als **Teilgebiet** der **Künstlichen Intelligenz** einordnen lässt
- was das **Grundprinzip der Klassifikation** ist, wie dieses **angewendet** werden kann und wie sich die folgenden Methoden unterscheiden:
 - **Entscheidungsbaum**
 - **Support Vector Machine (SVM)**
- was **Künstliche Neuronale Netze (KNN)** sind, wie diese **angewendet** werden können und wie sich die Folgenden unterscheiden:
 - **Perzeptron**
 - **Back-Propagation-Netz**
 - **Hopfield-Netz**

ANALYTICS-VERFAHREN VERWENDUNGSZWECK



Quelle Grafik: Gluchowski, Schieder, Chamoni 2021 nach Dorschel 2015.

Zuordnung von Objekten in undefinierte Gruppen (ohne Label Attribut)
„Unüberwachtes Lernen“

Auffinden von statistischen Zusammenhängen (Assoziation) zwischen verschiedenen Objekten in einem Datensatz.
Ableitung von signifikanten Assoziationsregeln.

Zuordnung von Objekten in zuvor definierte Klassen (basierend auf Beispieldatensätzen mit Label Attribut)
„Überwachtes Lernen“ (mit Training- und Test-Datensatz)


REGRESSION METHODEN

„Die Regressionsanalyse schätzt die funktionalen Abhängigkeiten zwischen Merkmalen um Zusammenhänge zu verstehen und gezielt zu steuern“

(Runkler 2015, S.67)

Häufig verwendete Methoden für die Regression:

- **Lineare Regression**
Lineare Regressionsmodelle können effizient aus den Kovarianzen berechnet werden, sind aber auf lineare Zusammenhänge beschränkt.
- **Robuste Regression**
Robuste Regression ist weniger empfindlich gegenüber Ausreißern
- **Nichtlineare Substitution**
Durch Substitution lassen sich auch bestimmte nichtlineare Regressionsmodelle durch lineare Regression finden
- **Universelle Approximatoren**
Eine Wichtige Familie nichtlinearer Regressionsmodelle sind universelle Approximatoren mit neuronalen Netzen bspw.:
 - **Mehrschichtiges Perzeptron**
 - **Radiale Basisfunktionen**




Quelle: Runkler, 2015, S. 68

PERZEPTRON

„Das **Perzeptron** ist ein sehr einfacher Klassifikationsalgorithmus. Es ist äquivalent zu einem zweilagigen gerichteten neuronalen Netzwerk mit Aktivierung durch eine Schwellwertfunktion.“ (W. Ertel, 2025)

- Jeder Knoten ein Neuron
- Jede Kante eine Synapse
- Eingabevariablen x (Features)
- Gewichtungen w
 - Lernender Agent mit einfacher Lernregel:
 - Wenn $wx > 0$, dann addiere x zum Gewichtsvektor w
 - $(w + x)x = wx + x^2$
 - Für negative Trainingsdaten
 - $(w - x)x = wx - x^2$



$$P(X) = \begin{cases} 1 & \text{falls } wx = \sum_{i=1}^n wix_i > 0 \\ 0 & \text{sonst} \end{cases}$$


Quelle: W. Ertel, Grundkurs Künstliche Intelligenz, 2025, S. 214.

MEHRSCHICHTIGES PERZEPTRON

“Ein **mehrschichtiges Perzeptron** ist ein (künstliches) Neuronales Netz, das wie ein gerichteter Graph dargestellt werden kann. Aufgrund der strukturellen Ähnlichkeit mit biologischen neuronalen Netzen werden die Knoten Neuronen genannt.”

(Runkler, 2015, S.73)

- **Neuronen** in mehreren Schichten angeordnet
- **Eingänge** sind die Neuronen der **ersten Schicht**
- **Ausgänge** sind die Neuronen der **letzten Schicht**
- Die **Schichten zwischen** Ein- und Ausgang heißen **verdeckte Schicht**
- Jede gerichtete Kante von Neuron i zu Neuron j besitzt ein Kantengewicht w



Quelle Grafik: Nach Runkler, 2015, S. 73.


KÜNSTLICHE NEURONALE NETZE (KNN)

Jedes Neuron bewertet ankommende Signale und verarbeitet sie zu einem ausgehenden Signal

Formal besteht ein Neuron aus :


- **Eingangssignalen** ($x_1, x_2, x_3, \dots, x_n$)
- Zugehörigen **Gewichten** ($w_1, \dots, w_n$)
- Einem **Schwellwert**
- Einer **Aktivierungsfunktion**, die den **Output** berechnet

Zuerst wird der Netinput als Summe der gewichteten Eingangssignale berechnet. Sofern die Signale größer als der Schwellwert sind, wird das Neuron aktiviert und beginnt einen Reiz auszusenden, es “feuert”. Der Output kann dann an ein nachfolgendes Neuron gesendet oder als Ausgabewert des Netzes genutzt werden.



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Für die Aktivierungsfunktion wird häufig eine binäre, lineare oder sigmoide Funktion verwendet.



HOPFIELD-NETZE


„Ganz zentral in der Theorie der neuronalen Netze ist die Modellierung des Lernens“ (W. Ertel, 2025)

- Eine Option des Lernens ist die **Stärkung von Synapsen** je mehr **Spannungsimpulse** sie übertragen muss.
- Prinzip wurde 1949 von D. Hebb postuliert und ist unter der **Hebb-Regel** bekannt:

„Wenn es eine Verbindung w_{ij} von Neuron j und Neuron i gibt und wiederholt Signale von Neuron j zu Neuron i geschickt werden, was dazu führt, dass die beiden Neuronen gleichzeitig aktiv sind, dann wird das Gewicht w_{ij} verstärkt. Eine mögliche Formel für die Gewichtsänderung Δw_{ij} ist:

$$\Delta w_{ij} = n x_i x_j$$

Mit der Konstante n (Lernrate), welche die Größe der einzelnen Lernschritte bestimmt.“




Rekurrente Verbindung von zwei Neuronen.

Quelle: Vgl. W. Ertel, 2025, S. 293

HOPFIELD-NETZE

- Bei der Hebb-Regel fällt auf, dass bei Neuronen mit **Werten zwischen 0 und 1** die **Gewichte** über die Zeit **nur wachsen** können
- Ein **Abschwächen** oder **Absterben** ist nach der Regel **nicht möglich**
- Das könnte jedoch durch eine **Zerfallsvariabel** modelliert werden, die ein unbenutztes Gewicht **pro Zeitschritt** um einen konstanten Faktor **abschwächt**
- Das **Modell von Hopfield** (1982) löst das Thema so, dass binäre Neuronen aber mit Werten von **-1 (nicht aktiv)** und **1 (aktiv)** verwendet werden
- So können **positive** wie **negative Beiträge zum Gewicht** entstehen.
- Durch seine **biologische Plausibilität** und das **mathematische Modell** trug das **Hopfield-Netze** in der 1980er Jahren zum Aufschwung der Neuroinformatik als Teilgebiet der KI bei.



Rekurrente Verbindung von zwei Neuronen.

Quelle: Vgl. W. Ertel, 2025, S. 293



BACK-PROPAGATION-NETZ

- Viel **genutztes** und **universell** einsetzbares neuronales Modell
- Kann über **mehr** als **2 Schichten** von Neuronen verfügen
- Als **Aktivierungsfunktion** wird die nichtlineare **Sigmoid-Funktion** auf die gewichtete Summe der Eingaben angewendet.
- Nach der Berechnung der Netzausgabe (**Vorwärtspropagieren**) für ein Trainingsbeispiel wird der **Approximationsfehler** berechnet
- Beim **Rückwärtspropagieren** wird dieser verwendet um von **Schicht zu Schicht** rückwärts die **Gewichte zu verändern**.
- Der Prozess wird dann auf alle **Trainingsbeispiele** angewendet und solange wiederholt bis sich die **Gewichte nicht** mehr **ändern** oder ein **Zeitlimit** erreicht wird
- Netze mit mindestens **1 verdeckten Schicht** können **nicht-lineare Abbildungen** erlernen
- Netze **ohne verdeckte Schicht** sind aufgrund der Sigmoid-Funktion nicht mächtiger als ein **lineares Neuron**.


Quelle: W. Ertel, Grundkurs Künstliche Intelligenz, 2025, S. 315-318.

Eigenschaften und Verteilungen

Auto und Marke



RELEVANTE DATEN UND PROGNOSEZIEL



Künstliche Neuronale Netze (KNN)

Übungsfragen



1. Was ist ein **Perzeptron** und aus welchen **Teilen** besteht es?
2. Was ist ein **Multilayer-Perzeptron**?
3. Nenne 3 **Aktivierungsfunktionen**!
4. Erkläre mit eigenen Worten die **Hebb-Regel**!
5. Welche Neuerung brachte das **Modell von Hopfield**?
6. Erkläre die Funktionsweise von **Backpropagation**!

Anwendungsbeispiel

Autopreisschätzer für Gebrauchtwagen


Szenario:

Ein Gebrauchtwagenhändler hat viele Daten über gebrauchte Fahrzeuge gesammelt. Er hat schon viel über Künstliche Neuronale Netze (KNN) gehört und möchte das Potenzial für die Schätzung der Preise seiner Gebrauchtwagen nutzen.

Ziel: Autopreisschätzer für Gebrauchtwagen mittels KNN erstellen

Vorgehen nach dem CRISP-DM Prozess in 6 Schritten:

1. Business Understanding (Aufgabendefinition)
2. Data Understanding (Auswahl der relevanten Datenbestände)
3. Data Preparation (Datenaufbereitung)
4. Modeling (Auswahl und Anwendung von Modellen)
5. Evaluation (Bewertung und Interpretation der Ergebnisse)
6. Deployment (Anwendung der Ergebnisse)




Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 3: Data Preparation

- Auswahl der Daten
 - Für die **Entscheidungsbaum-Methode** sind **numerische** Daten vorgesehen
- Bereinigung der Daten
 - **Fehlende Werte** entfernen oder Ersetzen
 - **Duplikate** entfernen
 - Evtl. **Ausreißer** ausschließen
- Transformation und Integration der Daten
 - Der Algorithmus ist abhängig von dem Skalenniveau
 - **Nominale Skalen** transformieren oder ausschließen
- Datenformatierung
 - Hohe Werte gehen stärker ein, eventuell **Werte Normieren**



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 4: Modeling

- Auswahl des Modells
 - Es soll ein Modell für die Vorhersage eines Preises für Gebrauchtwagen erstellt werden. Ziel ist demnach ein prediktives Modell.
 - [1.17. Neural network models \(supervised\) — scikit-learn 1.6.1 documentation](#)
- Testmodell erstellen
 - Auf Basis eines Trainings-Datensatzes
- Modell anwenden
 - Auf einen vollständigen Test-Datensatz.



INFOS ZU METHODEN IN SCIKIT-LEARN

1.17.1. Multi-layer Perceptron

Multi-layer Perceptron (MLP) is a supervised learning algorithm that learns a function $f : R^m \rightarrow R^o$ by training on a dataset, where m is the number of dimensions for input and o is the number of dimensions for output. Given a set of features $X = x_1, x_2, \dots, x_m$ and a target y , it can learn a non-linear function approximator for either classification or regression. It is different from logistic regression, in that between the input and the output layer, there can be one or more non-linear layers, called hidden layers. Figure 1 shows a one hidden layer MLP with scalar output.




Figure 1 : One hidden layer MLP.

Tipps zum Tuning des Modells:

1. Skalierung der Daten (sensitiv auf große Skalenunterschiede)
2. Die Anzahl verdeckter Schichten langsam steigern (bspw. bei 50 starten, dann auf 100 erhöhen)
3. Modell stoppen wenn es sich nicht mehr verbessert (`early_stopping=True`)
4. Verschiedene Lernrate ausprobieren, `learning_rate_init` (`learning_rates = [0.0001, 0.001, 0.01]`)
5. L2-Regularisierung (Strafterm für große Gewichte). Ein niedrigerer Wert führt zu einer komplexeren Anpassung (`alphas = [0.0001, 0.001, 0.01, 0.1]`)

Analyse von Gebrauchtwagendaten

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen



Making predictions for the following 5 cars:

	model	year	transmission	mileage	fuelType	tax	mpg	engineSize
0	A1	2017	Manual	15735	Petrol	150	55.4	1.4
1	A6	2016	Automatic	36203	Diesel	20	64.2	2.0
2	A1	2016	Manual	29946	Petrol	30	55.4	1.4
3	A4	2017	Automatic	25952	Diesel	145	67.3	2.0
4	A3	2019	Manual	1998	Petrol	145	49.6	1.0

The predictions are

```
[15178.51759016 17415.0243746 12718.03919921 18757.77555218  
19627.66539166]
```

Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 5: Evaluation


- Bewertung des Modells
 - ...
- Bewertung der Resultate
 - ...
- Bewertung des Prozesses
 - ...
- Nächste Schritte festlegen

	Echter Wert	Vorhergesagt	Abweichung
10442	9990	9360.405506	629.594494
2907	22382	20786.413192	1595.586808
7388	28990	29831.201088	-841.201088
3016	30777	27275.698159	3501.301841
7890	14950	14646.012919	303.987081
483	24365	22339.002409	2025.997591
5799	30495	35540.288364	-5045.288364
6026	29900	30426.573120	-526.573120
1084	15256	15464.610563	-208.610563
7873	24950	27621.265682	-2671.265682
	Echter Wert	Vorhergesagt	Abweichung
5459	133900	92749.571419	41150.428581
10468	125000	87001.353412	37998.646588
7644	48800	17383.650169	31416.349831
4742	117990	87451.747040	30538.252960
5707	116000	89149.340870	26850.659130
...	...	...	...
1498	26888	26890.880865	-2.880865
10264	11000	10997.372469	2.627531
2145	8895	8892.471324	2.528676
9567	28950	28951.953151	-1.953151
1369	18450	18450.994378	-0.994378

Anwendungsbeispiel

Schritt 5: Evaluation

- Bewertung des Modells
 - ...
 - Bewertung der Resultate
 - ...
 - Bewertung des Prozesses
 - ...
 - Nächste Schritte festlegen
-
- Jeder Punkt entspricht einer Vorhersage
 - Die **rote gestrichelte Linie** zeigt perfekte Vorhersage ($y = x$)
 - Je näher die Punkte an der Linie liegen, desto besser



Anwendungsbeispiel

Analyse von Gebrauchtwagendaten

Schritt 6: Deployment

- Zusammenfassender Bericht und Präsentation der Ergebnisse
- Implementierungsstrategie planen
 - Ergebnisse und Abweichungen in csv-Datei schreiben
 - Optional: Modellvergleich erstellen
- Überwachung der Gültigkeit der Modelle planen



```
Root Mean Squared Error: 3639.202789884522  
R2 Score: 0.9123678895655676
```

Künstliche Neuronale Netze (KNN)

25 Minuten Zeit



Aufgabe:

1. Findet euch in euren **Teams aus 2 Personen** zusammen.
2. Erstellt für den Datensatz zu Gebrauchtfahrzeugen eurer Automarke ein Notebook für einen Autopreisschätzer auf Basis eines künstlichen Neuronalen Netzes (KNN). Gehe nach den folgenden CRISP-DM Phasen vor:
 - **(Business Understanding)**
 - **(Data Understanding / EDA)**
 - **Data Preparation** (Transformationen für das Modell)
 - **Modeling** (Künstliches Neuronales Netz)
 - **Evaluation** (Bewertung und Interpretation der Ergebnisse)
 - **Deployment** (Anwendung der Ergebnisse)

Ihr könnt euch an dem Beispiel aus dem Notebook „**uc_knn_analysis_CRISP-DM.ipynb**“ orientieren.



Methoden und Anwendungen Künstlicher Intelligenz (KI)

Lernziele



Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich **maschinelles Lernen** als **Teilgebiet** der **Künstlichen Intelligenz** einordnen lässt
- was das **Grundprinzip der Klassifikation** ist, wie dieses **angewendet** werden kann und wie sich die folgenden Methoden unterscheiden:
 - **Entscheidungsbaum**
 - **Support Vector Machine (SVM)**
- was **Künstliche Neuronale Netze (KNN)** sind, wie diese **angewendet** werden können und wie sich die Folgenden unterscheiden:
 - **Perzeptron**
 - **Back-Propagation-Netz**
 - **Hopfield-Netz**

SUPPORT-VEKTOR-MASCHINEN

- **Gerichtete neuronale Netze** mit nur **einer Lage** von **Gewichten** sind **linear**
- **Linearität** führt zu **einfachen Netzen** und **schnellem Lernen** mit **Konvergenzgarantie**
- Gefahr des **Overfitting** geringer
- Bei vielen Anwendungen sind die **relevanten Klassen nicht linear separabel**
- Hier kommen **mehrschichtige Netze** wie **Back-Propagation** zum Einsatz
- Dabei können jedoch **lokale Maxima**, **Konvergenzprobleme** und **Overfitting** auftreten
- Die Theorie der **Support-Vektor-Maschinen (SVM)** ist ein Ansatz die Vorteile der **linearen** und **nichtlinearen Modelle** zu vereinen

1.4. Support Vector Machines

Support vector machines (SVMs) are a set of supervised learning methods used for [classification](#), [regression](#) and [outliers detection](#).

The advantages of support vector machines are:

- Effective in high dimensional spaces.
- Still effective in cases where number of dimensions is greater than the number of samples.
- Uses a subset of training points in the decision function (called support vectors), so it is also memory efficient.
- Versatile: different [Kernel functions](#) can be specified for the decision function. Common kernels are provided, but it is also possible to specify custom kernels.


The disadvantages of support vector machines include:

- If the number of features is much greater than the number of samples, avoid over-fitting in choosing [Kernel functions](#) and regularization term is crucial.
- SVMs do not directly provide probability estimates, these are calculated using an expensive five-fold cross-validation (see [Scores and probabilities](#), below).

Quelle: <https://scikit-learn.org/1.6/modules/svm.html>

SUPPORT-VEKTOR-MASCHINEN

- Gesucht ist eine Ebene, die **zu beiden linear separablen Klassen** einen möglichst **großen minimalen Abstand** hat
- Diese Ebene wird eindeutig definiert durch wenige **Punkte im Grenzbereich**
- Diese Punkte werden **Support-Vektoren** genannt und haben alle den **gleichen Abstand zur Trenngeraden**
- Die **Support Vektoren** können **durch effiziente Optimierungsalgorithmen** bestimmt werden
- Das beschriebene Verfahren wird nun **auf nicht linear separable Probleme** angewendet.



Quelle: https://scikit-learn.org/1.6/_images/sphx_glr_plot_separating_hyperplane_001.png


SUPPORT-VEKTOR-MASCHINEN

– Vorgehen in 2 Schritten:

1. Anwendung einer **nicht linearen Transformation** mit der Eigenschaft, dass die transformierten Daten linear separabel sind (immer möglich sofern die Daten keine Widersprüche enthalten).
2. Bestimmung der **Support-Vektoren** im transformierten Raum

„Die zentrale nicht lineare Transformation des Vektorraums wird als **Kernel** bezeichnet, weshalb die Support-Vektor-Maschinen auch unter dem Namen Kernel-Methoden bekannt sind“ (W. Ertel, 2025)

Die ursprünglich für **Klassifikation** entwickelte Theorie der SVMs ist somit auch auf **Regressionsprobleme** anwendbar.



Quelle: https://scikit-learn.org/1.6/_images/sphx_glr_plot_separating_hyperplane_001.png

Künstliche Neuronale Netze (KNN)

25 Minuten Zeit



Aufgabe:

1. Findet euch in euren **Teams aus 2 Personen** zusammen.
2. Erstellt für den Datensatz zu Gebrauchtfahrzeugen eurer Automarke ein Notebook für einen Autopreisschätzer auf Basis einer Support-Vektor-Machine (SVM). Gehe nach den folgenden CRISP-DM Phasen vor:
 - **(Business Understanding)**
 - **(Data Understanding / EDA)**
 - **Data Preparation** (Transformationen für das Modell)
 - **Modeling** (Support Vektor Machine)
 - **Evaluation** (Bewertung und Interpretation der Ergebnisse)
 - **Deployment** (Anwendung der Ergebnisse)

