

08

ANWENDUNGEN KÜNSTLICHER INTELLIGENZ (KI)

KURSinHALTE UND TERMINE

Kursinhalte

Data Science	1
Statistische Grundlagen	2
Softwareentwicklung	3
Analysemethoden, Clustering und Assoziationen	4
Grundlagen Künstlicher Intelligenz (KI)	5
Maschinelles Lernen, Klassifikation und Künstliche Neuronale Netze (KNN)	6
Testing / Integration / Delivery	7
Anwendungen Künstlicher Intelligenz (KI)	8
Zusammenfassung / Fragen / Klausurvorbereitung	9


Termine

#	Wochentag	Datum	von - bis	Räume
1	Freitag	04.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
2	Freitag	11.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.27 Bothfeld
3	Freitag	25.04.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
4	Freitag	16.05.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
5	Freitag	23.05.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
6	Freitag	06.06.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
7	Donnerstag	26.06.2025	13:15 - 16:30	HAN - Schiffgraben 49-51 - 0.07 Marktkirche
8	Freitag	04.07.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt
9	Freitag	11.07.2025	09:00 - 12:15	HAN - Schiffgraben 49-51 - 1.24 Südstadt

DATA SCIENCE

SOFTWARE ENGINEERING

MODULCODE: DSSE042401



BESCHREIBUNG DES KURSES

Ein zentraler Bestandteil von **Data Science** ist die **Wertschöpfung aus Daten**. Dieser Kurs gibt einen detaillierten Überblick über die **relevanten Methoden** und **Paradigmen**, die **Data Scientists** kennen müssen, um **unternehmenstaugliche Modelle** zu entwickeln. Der Kurs behandelt **traditionelle** und **agile Projektmanagement-Techniken**, wobei die Ansätze **Kanban** und **Scrum** im Vordergrund stehen. Es werden **relevante Softwareentwicklungsparadigmen** wie **Test-Driven Development**, **Pair Programming**, **Mob Programming** und **Extreme Programming** behandelt, wobei ein besonderer Schwerpunkt auf dem Thema **Testen** und der Überlegung liegt, wie man ein **Modell** in eine **Produktionsumgebung** bringt. Als weiterer Aspekt der Wertschöpfung von Daten wird das Thema **"Künstliche Intelligenz"** behandelt. Im Rahmen dessen werden bspw. Themen wie die **Entstehung künstlicher Intelligenz**, **Aufgaben** und **Methoden** von **künstlicher Intelligenz**, **regelbasierte** und **netzbasierte Vorgehensweisen**, Ansätze **neuronaler Netze**, die **Entwicklung** eigener **Anwendungen** mit **künstlicher Intelligenz** sowie eine Bewertung der **Möglichkeiten** und **Grenzen**, die das Thema "Künstlicher Intelligenz" bereithält, behandelt.

ART DER PRÜFUNG: KLAUSUR

DATA SCIENCE

SOFTWARE ENGINEERING

MODULCODE: DSSE042401

Kursinhalte

Klassisches Projektmanagement

- Anforderungsmanagement
- Wasserfallmodell
- Rationaler einheitlicher Prozess (RUP)

Agiles Projektmanagement

- Kritik am Wasserfallmodell
- Einführung in SCRUM
- Einführung in Kanban

Testing

- Warum Testing?
- Unit-Tests
- Integration-Tests
- Performance Monitoring

Paradigmen der Softwareentwicklung

- Test-Driven Development (TDD)
- Pair programming
- Mob programming
- Extreme Programmierung

Vom Modell zur Produktion

- Kontinuierliche Auslieferung
- Kontinuierliche Integration
- Aufbau einer skalierbaren Umgebung

Grundlagen künstlicher Intelligenz

- Grundbegriffe und Geschichte künstlicher Intelligenz
- Unsicheres Wissen und der Beitrag künstlicher Intelligenz im Wissensmanagement
- Agentensysteme


- Resolution, Unifikation, Hornklauseln und regelbasierte Wissensrepräsentation
- Backtraining, Unifikation und Ablaufsteuerung
- Problemlösung durch Suche

Methoden und Anwendungen künstlicher Intelligenz

- Neuronale Netze
- Das Perzeptron
- Back-Propagation-Netz
- Hopfield-Netze
- Data Mining und maschinelles Lernen
- Grundbegriffe und Klassifikationen
- Clustering
- Support Vector Machines

Organisatorisches – Erwartungen an den Kurs

Ergebnisse



Zusammenfassung:

- Projektmanagementtheorie nur kurz (da bereits bekannt!)
- Interessante Einblicke in KI mit vielen Anwendungsfällen / Beispielen / Aufgaben
- Vorgehen für Data Science Projekte (Planung, Umsetzung)
- Vertiefung Data Science und Machine Learning (ML)
- Vorbereitung auf die Klausur

Data Science Software Engineering

Kursevaluation 2025 SoSe

Um das E-Mailaufkommen schrittweise für die Studierenden der IU zu reduzieren, ist es für die Studierenden ab sofort möglich die Evaluationen direkt über **MyIU** durchzuführen.

Den folgenden Link und könnt Ihr in Eure Veranstaltungsmaterialien einbauen und somit direkt auf das neue Evaluations-Dashboard in MyIU verweisen.

Link: https://mycampus.iubh.de/local/iubh_generic/evasys.php

QR-Code: siehe Grafik



Läuft noch **bis zum 11.07.2025 23:59:00.**

Integration / Delivery

20 Minuten Zeit



Aufgabe:

Erstellt einen workflow für eure Gebrauchtwagen-Applikation.

1. Findet euch in euren Zweier-Teams zusammen und erstellt einen **Continuous Integration workflow** mittels **Github Actions**.
2. Der **workflow** soll mindestens:
 - **dependencies** installieren
 - (mit **Flake8** linten)
 - die **Tests ausführen**, die ihr erstellt habt (unittest oder pytest)
 - Einen **test coverage report** ausgeben (bspw. in html)



Anwendungen KI

Lernziele




Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich ganze **Data Science Anwendungen** erstellen lassen
- **Modularisierung** durch Trennung nach den **CRISP-DM Phasen**
 - Verwendung und Evaluation **alternativer Modelle**
 - Ergänzung von simplen **Eingabe- und Ausgabemasken**
- welche Aspekte beim **Betrieb** und der **Wartung** von **Data Science Anwendungen** hinzukommen
 - Welche Kriterien zur **Software-Qualitätssicherung** herangezogen werden können
- welche grundlegenden Prinzipien des **Datenschutzrechtes** zu beachten sind

MODULARISIERUNG NACH CRISP-DM PHASEN


	CRISP-DM Phase	Teilaufgaben	Umsetzungsvariante
1	Business Understanding (Aufgabendefinition)	- Bestimmung der betriebswirtschaftlichen Problemstellung - Situations-bewertung - Bestimmung analytischer Ziele - Erstellung eines Projektplans	Inhalte zu Zweck und Ziel können an übersichtlicher Stelle in das README file geschrieben werden
2	Data Understanding (Datenverständnis / EDA)	- Daten sammeln - Daten beschreiben - Untersuchung der Daten - Verifizierung der Datenqualität	- Daten in eigenem Pfad /data ablegen - Daten ausgiebig untersuchen, eda.py - Verständnis von Zusammenhängen durch univariat, bivariate und multivariate Analysen und Erzeugung von Diagrammen und Plots und in /data ablegen
3	Data Preparation (Datenaufbereitung)	- Auswahl der Daten - Bereinigung der Daten - Transformation und Integration der Daten - Daten-formatierung	- Nur relevante Daten auswählen - Daten speziell für das Modell aufbereiten (fehlende Werte, Ausreißer, Skalenniveaus, Verteilungen behandeln), preprocessing.py - Bei Bedarf aufbereitete Daten separat in /data ablegen



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

MODULARISIERUNG NACH CRISP-DM PHASEN

	CRISP-DM Phase	Teilaufgaben	Umsetzungsvariante
4	Modeling (Auswahl und Anwendung von Modellen)	- Auswahl des Modells - Testmodell erstellen - Modell erstellen	- Unterschiedliche Modelle ausprobieren und deren Ergebnisse evaluieren, modeling.py - Gute trainierte Modelle in eine Modelldatei speichern /model
5	Evaluation (Bewertung und Interpretation der Ergebnisse)	- Bewertung des Modells - Bewertung der Resultate - Bewertung des Prozesses - Nächste Schritte festlegen	- Bewertung sollte pro Modell erfolgen - Neben Gütekriterien sollten auch die Anwender / Fachexperten zu den Ergebnissen befragt werden
6	Deployment (Anwendung der Ergebnisse)	- Zusammenfassender Bericht und Präsentation der Ergebnisse - Implementierungs-strategie planen - Überwachung der Gültigkeit der Modelle planen	- Prozess zur Anwendung modellieren und dabei Tests einbauen /tests - Die Güte des Modells sollte regelmäßig überprüft werden



Quelle Grafik: Chapman, P., et al., 2000, CRISP-DM 1.0, S. 10.

PROJEKTBAUM

```
– uc_app/
– |── data/
– |   ├── audi.csv      # Rohdaten (z. B. aus Kaggle)
– |
– |── src/
– |   ├── __init__.py    # Macht src zum Package
– |   ├── preprocessing.py # Daten laden & bereinigen
– |   ├── modeling.py    # Modell-Training & ggf. Vorhersage
– |
– |── tests/
– |   ├── __init__.py
– |   ├── test_preprocessing.py # Unit-Tests für Preprocessing
– |   ├── test_modeling.py    # Unit-Tests für Modell-Training
– |   └── test_integration.py  # Integrationstest (Pipeline-Ende-zu-Ende)
– |
– |── model/
– |   └── audi_model.pkl  # gespeichertes Modell
– |
– |── requirements.txt    # Python-Abhängigkeiten
– |── README.md          # Projektbeschreibung
– └── main.py            # (Optional) Hauptskript für Training oder Deployment
```

Anwendungen KI

Lernziele



Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich ganze **Data Science Anwendungen** erstellen lassen
 - **Modularisierung** durch Trennung nach den **CRISP-DM Phasen**
 - **Verwendung und Evaluation alternativer Modelle**
 - Ergänzung von simplen **Eingabe- und Ausgabemasken**
- welche Aspekte beim **Betrieb** und der **Wartung** von **Data Science Anwendungen** hinzukommen
 - Welche Kriterien zur **Software-Qualitätssicherung** herangezogen werden können
 - welche grundlegenden Prinzipien des **Datenschutzrechtes** zu beachten sind

MODELL IN DATEI SPEICHERN

Eine **PKL-Datei** (Dateiendung: .pkl) ist eine Datei, die **serialisierte Objekte in Python** enthält. Sie wird vom **pickle-Modul** verwendet, das Datenstrukturen in ein **binäres Format** umwandelt, damit sie gespeichert oder über Netzwerke übertragen werden können.

Serialisieren = Python-Objekte (z. B. Listen, Dictionaries, Modelle) in eine speicherbare Form bringen.

Deserialisieren = Diese Form später wieder in echte Python-Objekte umwandeln.

Anwendung	Beispiel
Machine Learning	ML-Modelle (z. B. RandomForestClassifier) speichern
Daten-Cache	Große DataFrame-Daten als .pkl ablegen
Objektaustausch	Komplexe Python-Objekte zwischen Programmen teilen

Niemals `pickle.load()` auf **nicht vertrauenswürdige Dateien** anwenden!

Pickle-Dateien können **beliebigen Python-Code ausführen** → Sicherheitsrisiko!

MAIN.PY MIT JOBLIB

```
1  import joblib
2  from src.preprocessing import load_data, clean_data
3  from src.modeling import train_model
4  #from src.eda import exploratory_data_analysis
5
6  # Pfad zu den Daten
7  data_path = "data/audi.csv"
8
9  # Daten laden und aufbereiten
10 df = load_data(data_path)
11 df = clean_data(df)
12
13 # Features und target
14 X = df[["year", "mileage"]]
15 y = df["price"]
16
17 model = train_model(X, y)
18 print("Modell erfolgreich trainiert!")
19
20 # nach dem Training:
21 joblib.dump(model, "model/audi_model.pkl")
```

Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich ganze **Data Science Anwendungen** erstellen lassen
 - **Modularisierung** durch Trennung nach den **CRISP-DM Phasen**
 - Verwendung und Evaluation **alternativer Modelle**
 - Ergänzung von simplen **Eingabe- und Ausgabemasken**
- welche Aspekte beim **Betrieb** und der **Wartung** von **Data Science Anwendungen** hinzukommen
 - Welche Kriterien zur **Software-Qualitätssicherung** herangezogen werden können
 - welche grundlegenden Prinzipien des **Datenschutzrechtes** zu beachten sind



SIMPLE EINGABE UND AUSGABE

	Link	Beschreibung	Einsatzgebiete	Vorteile	Nachteile
tkinter	https://docs.python.org/3/library/tkinter.html	• Tkinter ist das Standard-GUI-Toolkit von Python für das Erstellen klassischer Desktop-Anwendungen (Windows, Mac, Linux). • Es basiert auf dem GUI-Toolkit Tcl/Tk und ist direkt in Python eingebaut – keine Installation nötig	• Formulareingaben • Tools mit Buttons, Listen, Eingabefeldern • Kleine lokale Anwendungen mit GUI	• Plattformunabhängig • Direkt in Python integriert • Gut für einfache Desktop-Tools	• Veraltet wirkendes Design • Keine moderne Webintegration • Weniger geeignet für Datenvisualisierung
streamlit	https://docs.streamlit.io/	• Streamlit ist ein modernes Python-Framework, mit dem du interaktive Web-Apps für Data Science und Machine Learning bauen kannst – ohne HTML, CSS oder JavaScript. • Apps laufen im Browser – lokal oder online.	• Data Science Dashboards • ML-Modell-Visualisierung • Interaktive Formulare & Plots	• Modernes Web-Design (out of the box) • Super einfach für Datenvisualisierung (z. B. matplotlib, pandas, plotly) • Ideal für Data Science und Rapid Prototyping	• Kein klassisches Fenster-GUI (nur Web) • Benötigt Webbrowser & Netzwerkzugang • Weniger flexibel für klassische Desktop-Funktionen (z. B. Dateioperationen)

TKINTER

im Terminal „python app.py“ ausführen

```
import tkinter as tk


# Hauptfenster erstellen
fenster = tk.Tk()

# Titel setzen (optional)
fenster.title("Meine Tkinter-App")

# Größe setzen (optional)
fenster.geometry("300x200")

# GUI-Schleife starten (wichtig!)
fenster.mainloop()
```

```
1 import tkinter as tk
2 from tkinter import messagebox
3 import joblib
4 import numpy as np
5
6 # Modell laden
7 try:
8     model = joblib.load("model/audi_model.pkl")
9 except Exception as e:
10     print("Fehler beim Laden des Modells:", e)
11     exit()
12
13 def predict_price():
14     try:
15         year = int(entry_year.get())
16         mileage = int(entry_mileage.get())
17
18         # Modellvorhersage
19         input_data = np.array([[year, mileage]])
20         predicted_price = model.predict(input_data)[0]
21
22         label_result.config(text=f"Vorhergesagter Preis: {predicted_price:.2f} €")
23     except ValueError:
24         messagebox.showerror("Fehler", "Bitte gültige Zahlen eingeben.")
25     except Exception as e:
26         messagebox.showerror("Modellfehler", str(e))
27
28 # GUI aufbauen
29 root = tk.Tk()
30 root.title("Audi Preisvorhersage")
31
32 tk.Label(root, text="Baujahr (year):").grid(row=0, column=0, padx=10, pady=5)
33 entry_year = tk.Entry(root)
34 entry_year.grid(row=0, column=1, padx=10, pady=5)
35
36 tk.Label(root, text="Kilometerstand (mileage):").grid(row=1, column=0, padx=10, pady=5)
37 entry_mileage = tk.Entry(root)
38 entry_mileage.grid(row=1, column=1, padx=10, pady=5)
39
40 btn_predict = tk.Button(root, text="Preis vorhersagen", command=predict_price)
41 btn_predict.grid(row=2, column=0, columnspan=2, pady=10)
42
43 label_result = tk.Label(root, text="Vorhergesagter Preis:", font=("Arial", 12, "bold"))
44 label_result.grid(row=3, column=0, columnspan=2, pady=10)
45
46 root.mainloop()
```



<https://docs.python.org/3/library/tkinter.html>

Per Kommandozeile oder PowerShell zum Pfad mit dem File navigieren

„streamlit run app.py“

Ausgabe via browser und localhost:8501

```
1  import streamlit as st
2  import joblib
3  import numpy as np
4
5  # Modell laden
6  @st.cache_resource
7  def load_model():
8      return joblib.load("model/audi_model.pkl")
9
10 model = load_model()
11
12 # Titel
13 st.title("🚗 Audi Preisvorhersage")
14 st.markdown("Gib unten das Baujahr und den Kilometerstand ein, um den geschätzten Fahrzeugpreis zu berechnen.")
15
16 # Eingabefelder
17 year = st.number_input("Baujahr", min_value=1990, max_value=2025, value=2018)
18 mileage = st.number_input("Kilometerstand", min_value=0, max_value=500000, value=50000, step=1000)
19
20 # Vorhersagebutton
21 if st.button("📄 Preis vorhersagen"):
22     input_data = np.array([[year, mileage]])
23     predicted_price = model.predict(input_data)[0]
24     st.success(f"🔥 Geschätzter Preis: {predicted_price:,.2f} €")
```

<https://docs.streamlit.io/>

Audi Preisvorhersage

Gib Baujahr und Kilometerstand ein, um den geschätzten Preis zu berechnen.

Baujahr

2021

- +

Kilometerstand

60000

- +

 Preis berechnen

🔥 Vorhergesagter Preis: 29,265.39 €

⚠️ Keine ähnlichen Fahrzeuge in den Daten gefunden.



Aufgabe:

Erstelle eine einfache **Data Science Anwendung** für die Prognose des Preises von Gebrauchtwagen.


1. Sofern noch nicht umgesetzt, erstellt eine **Projektstruktur** für eure Anwendung, ähnlich dem Projektbaum (**data, src, tests, model, requirements.txt, README.md**)
2. Erstellt eine Datei für die **explorative Datenanalyse (eda.py)** und speichert mindestens ein diagramm oder plot als Bild-Datei unter **/data**
3. Erstellt eine Datei für die **data preparation (preprocessing.py)**, in der die Daten für das Methode aufbereitet werden
4. Erstellt eine Datei für das Modell und die Evaluation von passenden Gütekriterien (modeling.py)
5. Erstellt eine Datei **main.py** in der die aufbereiteten Daten geladen und das konfigurierte Modell ausgeführt und in eine Datei xy_model.pkl gespeichert wird
6. Erstelle eine Datei **app.py** die über eine simple GUI nach den Eingabeparametern fragt und die den errechneten Preis auf Basis des Modells ausgibt.
7. Ergänze die Ausgabe um ein Gütekriterium

Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich ganze **Data Science Anwendungen** erstellen lassen
 - **Modularisierung** durch Trennung nach den **CRISP-DM Phasen**
 - Verwendung und Evaluation **alternativer Modelle**
 - Ergänzung von simplen **Eingabe- und Ausgabemasken**
- welche Aspekte beim **Betrieb** und der **Wartung** von **Data Science Anwendungen** hinzukommen
- Welche Kriterien zur **Software-Qualitätssicherung** herangezogen werden können
- welche grundlegenden Prinzipien des **Datenschutzrechtes** zu beachten sind



FUNKTIONALE UND NICHT-FUNKTIONALE ANFORDERUNGEN



Quelle: https://www.peterjohann-consulting.de/nicht-funktionale-anforderungen/?utm_source=chatgpt.com

ISO – INTERNATIONAL ORGANIZATION FOR STANDARDIZATION

Practical solutions for real-world problems

ISO, the International Organization for Standardization, brings global experts together to agree on the best way of doing things – for anything from making a product to managing a process. As one of the oldest non-governmental international organizations, ISO has enabled trade and cooperation between people and companies all over the world since 1946. The International Standards published by ISO serve to make lives easier, safer and better.

25866

International Standards and other deliverables covering almost all aspects of technology, management and manufacturing.

174


Members representing ISO in their country.
There is only one member per country.

827

Technical committees and subcommittees to take care of standards development.

ISO 25010:2023 – SYSTEM- UND SOFTWAREQUALITÄT


“Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE) — Product quality model“



Quelle: <https://sw-qs.blogspot.com/2015/10/einfuehrung-software-qualitaetssicherung.html>

ISO 25010:2023 – SYSTEM- UND SOFTWAREQUALITÄT

“Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE) — Product quality model“



Quelle: <https://sw-qs.blogspot.com/2015/10/einfuehrung-software-qualitaetssicherung.html>

Anwendungen KI

Lernziele



Nach der Bearbeitung dieser Lektion werdet ihr wissen, ...

- wie sich ganze **Data Science Anwendungen** erstellen lassen
 - **Modularisierung** durch Trennung nach den **CRISP-DM Phasen**
 - Verwendung und Evaluation **alternativer Modelle**
 - Ergänzung von simplen **Eingabe- und Ausgabemasken**
- welche Aspekte beim **Betrieb** und der **Wartung** von **Data Science Anwendungen** hinzukommen
 - Welche Kriterien zur **Software-Qualitätssicherung** herangezogen werden können
 - welche grundlegenden Prinzipien des **Datenschutzes** zu beachten sind

RECHTLICHE ASPEKTE DER DATENANALYSE

DATENSCHUTZRECHT PRINZIPIEN

Der Gesetzgeber orientiert sich an **grundlegenden Prinzipien des Datenschutzrechts**, zu finden in den allgemeinen Datenschutzgesetzen wie dem **Bundesdatenschutzgesetz (BDSG)** oder den jeweiligen Landesschutzgesetzen.

Verbot mit Erlaubnisvorbehalt

- Deutsches Datenschutzrecht folgt konstruktiv dem Prinzip des **Verbots mit Erlaubnisvorbehalt**, so ist die **Erhebung, Verarbeitung oder Nutzung personenbezogener Daten grundsätzlich verboten**, es sei denn der Betroffene willigt darin ein oder ein Gesetz bzw. eine Rechtsvorschrift erlaubt es.
- Jeder einzelne **Verarbeitungsschritt** in einer Big Data Anwendung ist daher auf seine rechtliche Zulässigkeit zu prüfen (von Datenerhebung, Datenverarbeitung, bis Datennutzung).
- **Einwilligung** ist häufig kein taugliches Instrument, da der Einwilligende über Art, Umfang und Zweck informiert sein muss und ausdrücklich, freiwillig und formgerecht zugestimmt haben muss.
- „Entscheidend ist stets, dass die **Interessen des Datenverarbeiters** gegenüber den schutzwürdigen Interessen des betroffenen überwiegen“

Prinzipien:

1. **Verbot mit Erlaubnisvorbehalt**
2. Zweckbindung
3. Transparenz
4. Unmittelbarkeit der Datenerhebung
5. Datensparsamkeit

RECHTLICHE ASPEKTE DER DATENANALYSE

DATENSCHUTZRECHT PRINZIPIEN

Zweckbindung

- **Zweckbindungsgrundsatz** besagt, dass die Daten nur zu dem Zweck verarbeitet und genutzt werden dürfen, zu dem sie ursprünglich erhoben wurden.
- Der **Verarbeitungszweck** ist somit bereits bei der Erhebung dem betroffenen mitzuteilen.
- Ohne legitimen Verarbeitungszweck für personenbezogenen Daten kann die Erforderlichkeit nicht geprüft und keine **Abwägungsentscheidung** getroffen werden.
- „Personenbezogene Daten auf Vorrat zu unbestimmten oder noch nicht bestimmbaren Zwecken zu sammeln, ist unzulässig (BVerfG NJW 1984, S 419 [422]).“ (Culmsee, in Dorschel 2015, S. 169.)
- Datenschutzrechtliche Gestaltungsspielräume können sich im Zusammenhang mit **öffentlich zugänglichen Daten** ergeben.
- „**Öffentlich zugänglich** sind Daten, die allgemein zugänglich gemacht werden dürfen oder die ihrer Intention und technischen Gestaltung nach nicht auf den Zugriff durch einen eingeschränkten Nutzerkreis beschränkt sind (Gola und Schomerus 2015, S. 436f; Weichert 2013, S. 257)“
- Dazu zählen Quellen wie **Zeitungen, öffentliche Register** wie das Handelsregister oder **Internetdaten**, sofern der Zugriff für jedermann offen ist also bspw. kein Login-Verfahren notwendig ist.
- Bei einem **Widerspruch der Betroffenen** oder besonderen personenbezogenen Daten wie **Gesundheitsdaten** ändert sich die Pauschalisierung der **Betroffeneninteressen** wieder.

Culmsee, in Dorschel 2015, S. 169f.

Prinzipien:

1. Verbot mit Erlaubnisvorbehalt
2. **Zweckbindung**
3. Transparenz
4. Unmittelbarkeit der Datenerhebung
5. Datensparsamkeit

RECHTLICHE ASPEKTE DER DATENANALYSE

DATENSCHUTZRECHT PRINZIPIEN

Prinzip der Transparenz

- Ist in verschiedenen Datenschutzrechtlichen Vorschriften umgesetzt.
- Betroffene kann Auskunft über die Erhebung, Verarbeitung und Nutzung seiner personenbezogenen Daten verlangen.
- Benachrichtigungs- und Informationspflichten, bspw. im Falle einer Datenschutzpanne
- Bei Big Data Anwendungen Verlagerung von der individuellen auf die institutionelle Ebene
- Zuständig ist häufig der Datenschutzbeauftragte in Abstimmung mit den Aufsichtsbehörden

Unmittelbarkeit der Datenerhebung

- Nach dem Direkterhebungsgrundsatz sind personenbezogene Daten grundsätzlich beim Betroffenen zu erheben (§ 4 Abs. 2 S. 1 BDSG)

Prinzipien:

1. Verbot mit Erlaubnisvorbehalt
2. Zweckbindung
3. **Transparenz**
4. **Unmittelbarkeit der Datenerhebung**
5. Datensparsamkeit

RECHTLICHE ASPEKTE DER DATENANALYSE

DATENSCHUTZRECHT PRINZIPIEN

Datensparsamkeit

- **Grundsatz der Datenvermeidung** und **Datensparsamkeit** verlangt Systeme so zu gestalten, dass möglichst wenig oder gar keine personenbezogenen Daten erhoben, verwendet oder genutzt werden.
- Hat eher den Rang einer **Zielvorgabe**, Verstoß führt nicht direkt zu Unzulässigkeit der Datenverarbeitung
- **Technische Konkretisierungen** des Grundsatzes finden sich in der **Anonymisierung** und der **Pseudonymisierung** personenbezogener Daten wieder
- „**Anonymisierung** setzt voraus, dass personenbezogene Daten derart verändert werden, dass sie nicht mehr oder nur mit einem unverhältnismäßig großem Aufwand an Zeit, Kosten und Arbeitskraft einer bestimmten oder unbestimmten natürlichen Person zugeordnet werden können (§ 3 Abs. 6 BDSG).“
- Person ist bestimmt oder bestimmbar, wenn sie über bestimmte Merkmale direkt oder indirekt identifiziert werden kann
- Anonymisierung kann bspw. durch Zerlegung der Datensätze in nicht-identifizierbare Teile oder durch Aggregation von Einzeldaten zu Gruppendatensätzen erfolgen
- Für Big Data Anwendungen ist die Anonymisierung ein wichtiges Konzept einer Datenschutzkonformen Ausgestaltung

Prinzipien:

1. Verbot mit Erlaubnisvorbehalt
2. Zweckbindung
3. Transparenz
4. Unmittelbarkeit der Datenerhebung
5. **Datensparsamkeit**

RECHTLICHE ASPEKTE DER DATENANALYSE

DATENSCHUTZRECHT PRINZIPIEN

Datensparsamkeit

- „Nach § 3 Abs. 6a BDSG bezeichnet das **Pseudonymisieren** den Vorgang des Ersetzens des Namens und anderer Identifikationsmerkmale durch ein Kennzeichen, sodass die Bestimmung des Betroffenen ausgeschlossen oder wesentlich erschwert wird.“
- Mittels eine Zuordnungsfunktion können jedoch im Nachhinein Datensätze und Personen zugeordnet werden
- Kodierung zum Beispiel mittels Kundennummer, Mitgliedsnummer, Sozialversicherungsnummer
- Separierung von sensiblen, personenbezogenen Daten und den Schlüsseldaten
- Leicht Identifizierbare Pseudonyme wie eine Zusammensetzung aus Name, Wohnort und Geburtsdatum reichen in aller Regel nicht aus
- Reduzierung der Stellen, die überhaupt Zugriff auf Zuordnungstabellen haben
- Verarbeitung und Nutzung der pseudonymisierten Daten darf nur durch Stellen stattfinden, die keinen Zugriff auf die Zuordnungsfunktion haben
- Mithilfe von **Verschlüsselung** kann ebenfalls eine Art der Pseudonymisierung erreicht werden

Prinzipien:

1. Verbot mit Erlaubnisvorbehalt
2. Zweckbindung
3. Transparenz
4. Unmittelbarkeit der Datenerhebung
5. **Datensparsamkeit**

RECHTLICHE ASPEKTE DER DATENANALYSE

INTERNATIONALE DATENVERARBEITUNG

„Grenzüberschreitende Datenverarbeitung ist mit besonderen datenschutzrechtlichen Problemen behaftet. Grund hierfür ist die unterschiedliche Ausgestaltung der nationalen Datenschutzregime und damit verbunden auch der Schutzniveaus“

(Botzem, in Dorschel 2015, S. 199)

– Grenzüberschreitende Datenverarbeitung in der EU

- Innerhalb der EU gilt das „**Sitzlandprinzip**“
- Es ist grundsätzlich das **nationale Recht des Staates** zu verwenden, in dem die **verantwortliche Stelle** ihren **Sitz** hat, Ort wo die Daten verarbeitet werden nicht maßgeblich
- Vorteil ist, dass Unternehmen sich nicht mit den verschiedenen Ausprägungen des jeweiligen nationalen Datenschutzrechts auseinander setzen müssen
- Bei mehreren **Niederlassungen** außerhalb des Sitzlandes ist zu beachten, ob die Datenverarbeitung nur als **Auftragnehmer** in den Niederlassungen ausgeführt wird. Andernfalls finden nationale Vorschriften Anwendung.
- Nach BDSG ist eine schriftliche Vereinbarung zur **Auftragsdatenverarbeitung** zwischen **Auftraggeber** und **Auftragnehmer** für die **Verarbeitung von personenbezogenen Daten** zu erteilen.



Botzem, in Dorschel 2015, S. 199-204.

RECHTLICHE ASPEKTE DER DATENANALYSE

INTERNATIONALE DATENVERARBEITUNG

Grenzüberschreitende Datenverarbeitung in Drittstaaten (nicht Mitgliedstaaten der EU)

- Bei der Datenverarbeitung in Drittstaaten (außerhalb der EU) wird das „**Territorialprinzip**“ angewendet
- Danach ist der **Ort der Datenverarbeitung** maßgeblich
- Bei Datenverarbeitung **über das Internet** ist der Ort des Hostings der Website, also der Serverstandort zu verwenden
- Eine **Anmeldung** eines Nutzers über eine **Website** und die **Nutzung** von **Telekommunikationseinrichtungen** in einem Land reichen nicht für die Relevanz einer Anwendung des nationalen Datenschutzrechts des Landes in dem sich der Nutzer befindet
- **Voraussetzungen:**
 - Übermittlung der Daten in Drittstaaten muss **durch BDSG** oder anderes **Gesetz legitimiert** sein oder der **Betroffene willigt** in die Übermittlung **ein**
 - **Schutzwürdige Interessen** des **Betroffenen** müssen **gewahrt** bleiben (bspw. Nicht der Fall wenn das verarbeitende Land aus Sicht der EU kein angemessenes Datenschutzniveau hat)



RECHTLICHE ASPEKTE DER DATENANALYSE

INTERNATIONALE DATENVERARBEITUNG

Grenzüberschreitende Datenverarbeitung in Drittstaaten (nicht Mitgliedstaaten der EU)

- Die zuständige Aufsichtsbehörde kann Genehmigungen zur Datenübermittlung erteilen (ausreichende Garantien für den Datenschutz notwendig)
- **EU-Standardvertragsklauseln** für die Übermittlung personenbezogener Daten in Drittländer
Sofern diese genutzt werden, kann eine Genehmigung durch die zuständige Aufsichtsbehörde entfallen
- **Binding Corporate Rules (BCR)**
Datenschutzrechtlich gibt es kein Konzernprivileg und somit ist eine Übermittlung personenbezogener Daten (insbesondere Mitarbeiterdaten) von einer Konzerngesellschaft zu einer anderen nicht zulässig. Durch die BCR wird konzerninterne Datenverkehr erst legitimiert.
- **Safe Harbour Principles**
Gemeinsamer Maßstab für angemessenes Datenschutzniveau zwischen europäischer Kommission und amerikanischem Handelsministerium. Nur die Verpflichtung zur Einhaltung reicht nach deutschen Datenschutzbehörden jedoch nicht aus, um Datentransfer in die USA datenschutzkonform abzubilden. Deutsche Unternehmen müssen sich von den amerikanischen Unternehmen einen Nachweis über die Einhaltung der Prinzipien geben lassen. Wegen fehlender staatlicher Kontrollen wird das Programm eher kritisch gesehen.

